

به نام خدا

گزارش پروژه درس «تحلیل کلان داده»

استاد درس: دکتر مصطفی حقیرچهرقانی

دانشجو: محسن الهی فرد

شماره دانشجویی: ۴۰۴۱۳۱۰۹۴

مردادماه ۱۴۰۵



فهرست مطالب

فصل اول – مبانی نظری و بررسی معماری چارچوب پیشنهادی.....	۶
۱.۱. مقدمه‌ای بر سیستم‌های توصیه‌گر و چالش پراکندگی داده‌ها.....	۶
۱.۲. عبور از مدل‌های سنتی به سمت یادگیری عمیق در سیستم‌های توصیه‌گر.....	۶
۱.۳. اطلاعات جانبی و محدودیت مدل‌های فعلی.....	۷
۱.۴. معرفی راهکار پیشنهادی: مدل FSTDMF.....	۸
۱.۵. فرمول‌بندی ریاضی DMF.....	۹
۱.۶. ترکیب مدل DMF با نیمه‌خودرمزگذار.....	۱۰
۱.۷. مدل DMF از طریق انتقال زیرفضای ویژگی.....	۱۱
۱.۸. یادگیری بازنمایی‌های پنهان از اطلاعات جانبی آیت‌ها.....	۱۲
۱.۹. استخراج ویژگی از ماتریس امتیازات در دامنه‌های دیگر.....	۱۲
۱.۱۰. جمع‌بندی: ساختار کلی مدل FSTDMF.....	۱۳
فصل دوم – پاسخ به سوالات تئوری.....	۱۴
۲.۱. مسئله اصلی پژوهش و ضعف‌های رویکردهای موجود.....	۱۴
۲.۲. معماری مقداردهی اولیه و مکانیزم انتقال زیرفضای ویژگی.....	۱۵
۲.۳. نقش و تحلیل پارامتر اطمینان در مدل پیشنهادی.....	۱۶
۲.۴. معیارهای ارزیابی و بررسی بهبود عملکرد مدل.....	۱۷
۲.۵. مطالعه فرسایشی (حذف اجزا) و تأثیر ابعاد داده‌ها.....	۱۷
فصل سوم – تشریح پیاده‌سازی عملی و ساختار کد.....	۱۹
۳.۱. آماده‌سازی داده‌ها و استخراج ویژگی‌های جانبی.....	۱۹
۳.۲. معماری شبکه‌های عصبی و پیاده‌سازی با PyTorch.....	۱۹
۳.۳. فرمول‌بندی تابع زیان و ترفند مقیاس‌بندی ریاضی.....	۲۰
۳.۴. پیش‌آموزش نیمه‌خودرمزگذار و حلقه‌های آموزش شبکه.....	۲۲
۳.۵. تقسیم‌بندی داده‌ها و مکانیزم ارزیابی مدل.....	۲۳
۳.۶. معماری اجرای سناریوها و تولید خروجی‌ها.....	۲۳
فصل چهارم – نتایج آزمایش‌ها، ارزیابی و تحلیل عملکرد مدل.....	۲۵
۴.۱. مقدمه و تنظیمات اجرایی ارزیابی.....	۲۵
۴.۲. ارزیابی عملکرد روی مجموعه‌داده MovieLens-100K.....	۲۵
۴.۳. ارزیابی عملکرد روی مجموعه‌داده MovieLens-1M.....	۲۶
۴.۴. تحلیل حساسیت نسبت به ابعاد ویژگی پنهان.....	۲۷

۴.۵.	تحلیل حساسیت نسبت به تعداد لایه‌های پنهان.....	۲۸
۴.۶.	مطالعه فرسایشی (حذف اجزا) و تحلیل اثربخشی اجزای مدل.....	۳۰
	فصل پنجم – نتیجه‌گیری و جمع‌بندی نهایی.....	۳۲
۵.۱.	مرور کلی مسئله و نوآوری‌های معماری.....	۳۲
۵.۲.	دستاوردهای پیاده‌سازی عملی و چالش‌های فنی.....	۳۲
۵.۳.	جمع‌بندی تحلیل‌ها و ارزیابی‌های تجربی.....	۳۳
۵.۴.	پیشنهاداتی برای پژوهش‌ها و توسعه‌های آتی.....	۳۴

فهرست اشکال

- شکل ۱: نمودار خطای MAE بر حسب ابعاد ویژگی پنهان (۲) در مدل‌های DMF و FSTD MF با نسبت‌های آموزش ۰/۵، ۰/۷ و ۰/۳ روی مجموعه داده MovieLens-1M ۲۷
- شکل ۲: روند تغییرات خطای MAE در مدل پیشنهادی FSTD MF به‌ازای افزایش تعداد لایه‌های پنهان در نسبت‌های مختلف آموزش (مجموعه داده MovieLens-100K) ۲۹
- شکل ۳: نمودار میله‌ای مقایسه خطای MAE در مطالعه فرسایشی میان چهار معماری مختلف شبکه روی مجموعه داده MovieLens-100K ۳۰

فهرست جداول

- جدول ۱: مقایسه خطای پیش‌بینی میان مدل DMF و FSTD MF روی مجموعه داده MovieLens-100K با مقادیر مقاله اصلی ۲۵
- جدول ۲: مقایسه خطای پیش‌بینی میان مدل DMF و FSTD MF روی مجموعه داده MovieLens-1M با مقادیر مقاله اصلی ۲۶
- جدول ۳: مقایسه خطای MAE و RMSE در لایه‌های مختلف میان پیاده‌سازی عملی و جدول ۸ مقاله (MovieLens-100K) ۲۹

فصل اول – مبانی نظری و بررسی معماری چارچوب پیشنهادی

۱.۱. مقدمه‌ای بر سیستم‌های توصیه‌گر^۱ و چالش پراکندگی داده‌ها^۲

رشد نمایی اطلاعات آنلاین باعث شده است تا توسعه و کاربرد سیستم‌های توصیه‌گر تسریع شود. این سیستم‌ها ابزارهایی کلیدی برای کاهش چالش اضافه‌بار اطلاعات^۳ هستند و در پلتفرم‌های مختلفی مانند آمازون، تائوبائو، فیس‌بوک و غیره کاربرد دارند. سیستم‌های توصیه‌گر با تحلیل سوابق تعاملات پیشین کاربران، اطلاعات یا محصولات را پیشنهاد می‌دهند که با ترجیحات کاربر هم‌راستا باشند.

به‌طور کلی، تکنیک‌های سنتی مورد استفاده در سیستم‌های توصیه‌گر در دو دسته اصلی قرار می‌گیرند:

- روش‌های مبتنی بر محتوا^۴: در این رویکرد، آیتم‌ها با رسم شباهت میان آن‌ها و ترجیحات تاریخی کاربر پیشنهاد داده می‌شوند.
- پالایش مشارکتی^۵: این تکنیک‌ها عمدتاً بر معیارهای شباهت کاربر یا آیتم تکیه دارند تا توصیه‌ها را فرمول‌بندی کنند. تمام این رویکردها با یادگیری ماشین در ارتباط هستند.

روش‌های پالایش مشارکتی به‌دلیل پیاده‌سازی ساده و کارایی بالا، به‌صورت گسترده پذیرفته شده‌اند. بخش قابل‌توجهی از این رویکردها بر پایه فاکتورگیری ماتریس^۶ هستند. با این حال، اکثر مدل‌های موجود فاکتورگیری ماتریس در یادگیری ویژگی‌های غیرخطی ضعف دارند.

علاوه بر این، مسئله پراکندگی به‌عنوان یک گلوگاه و چالش اصلی برای فاکتورگیری ماتریس شناخته می‌شود. در محیط‌های واقعی، ماتریس امتیازات کاربران به آیتم‌ها معمولاً بسیار خلوت است و این کمبود داده باعث می‌شود تا روش‌های پالایش مشارکتی سنتی اثربخشی خود را از دست بدهند. این محدودیت باعث شده است تا محققان به‌سمت ادغام تکنیک‌های جدیدتری مانند یادگیری عمیق^۷ حرکت کنند تا بر این مشکلات غلبه کنند.

۱.۲. عبور از مدل‌های سنتی به‌سمت یادگیری عمیق در سیستم‌های توصیه‌گر

اخیراً روش‌های یادگیری عمیق قدرت خود را در یادگیری بازنمایی ویژگی‌های پنهان^۸ نشان داده‌اند و کاربردهای گسترده‌ای در زمینه‌های مختلف پیدا کرده‌اند. با الهام از این پیشرفت‌ها، بسیاری از کارهای تحقیقاتی یادگیری عمیق را با فاکتورگیری ماتریس ترکیب کرده و مدل‌های فاکتوریزاسیون ماتریس عمیق^۹ یا DMF را پیشنهاد داده‌اند تا بر کاستی‌های روش‌های پیشین غلبه کنند.

¹ Recommendation Systems

² Data Sparsity

³ Information Overload

⁴ Content-based Methods

⁵ Collaborative Filtering

⁶ Matrix Factorization

⁷ Deep Learning

⁸ Latent Feature Representation

⁹ Deep Matrix Factorization

در هسته متدولوژی‌های DMF، استفاده از یادگیری عمیق برای ساخت یک مدل غیرخطی قرار دارد که از محدودیت‌های پارادایم‌های فاکتورگیری ماتریس خطی و سنتی فراتر می‌رود. همزمان با پیشرفت‌های سریع در یادگیری عمیق، مدل‌های متعددی مبتنی بر معماری‌های عمیق راه خود را در سیستم‌های توصیه‌گر پیدا کرده‌اند. این معماری‌های در حال تکامل شامل موارد زیر هستند اما به آن‌ها محدود نمی‌شوند:

- پرسپترون چندلایه‌ای^{۱۰}
- شبکه‌های عصبی پیچشی^{۱۱}
- شبکه‌های عصبی بازگشتی^{۱۲}
- شبکه‌های تخصصی^{۱۳}
- خودرمزگذار^{۱۴}

در این میان، خودرمزگذارها به‌عنوان رویکردی محبوب و موردتوجه در این حوزه متمایز شده‌اند. برای مثال، در برخی پژوهش‌ها از یک رمزگذار خودکار برای یادگیری بازنمایی ویژگی‌های کاربران یا آیتم‌ها به‌منظور پیاده‌سازی پالایش مشارکتی استفاده شده است. یکی دیگر از روش‌های پرکاربرد، پرسپترون چندلایه‌ای است. محققان با بهره‌گیری از شبکه‌های عصبی چندلایه برای یادگیری بازنمایی‌های پنهان کاربران یا آیتم‌ها، توانسته‌اند مدل متغیر پنهان غیرخطی را تقریب بزنند. این مدل همه‌کاره‌تر است و برای وظایف مختلف تکمیل ماتریس^{۱۵} کاربرد دارد و نتایج رضایت‌بخشی نیز به‌دست آورده است.

۱.۳. اطلاعات جانبی^{۱۶} و محدودیت مدل‌های فعلی

اکثر روش‌هایی که اطلاعات جانبی را از کاربران و یا آیتم‌ها به مدل معرفی می‌کنند، توانایی قابل‌توجهی در رسیدگی به چالش پراکندگی داده‌ها نشان داده‌اند. برای مثال، برخی از محققان با اضافه کردن صفات جانبی کاربر یا آیتم به مدل پالایش مشارکتی، دقت پیش‌بینی امتیازها را بهبود بخشیده‌اند. با این حال، به‌دلیل هزینه بالای استخراج دانش برچسب‌دار و همچنین افزایش آگاهی عمومی در زمینه حفظ حریم خصوصی کاربران^{۱۷}، جمع‌آوری و استفاده از اطلاعات جانبی دشوارتر از گذشته شده است.

رویکرد جایگزین دیگری که در برخی پژوهش‌ها مورد استفاده قرار گرفته، بهره‌گیری از اطلاعات امتیازدهی در دامنه‌های کاملاً مرتبط با استفاده از متدولوژی‌های یادگیری انتقال^{۱۸} است. اما این روش نیز نقاط ضعف خود را دارد؛ یادگیری انتقال اغلب زمانی که تفاوت‌های بزرگی در ساختار داده‌های امتیازدهی میان دامنه‌های مختلف وجود داشته باشد، با شکست مواجه می‌شود.

¹⁰ Multi-Layer Perceptron (MLP)

¹¹ Convolutional Neural Network (CNN)

¹² Recurrent Neural Network (RNN)

¹³ Adversarial Networks

¹⁴ Autoencoders

¹⁵ Matrix Completion

¹⁶ Auxiliary Information

¹⁷ User Privacy

¹⁸ Transfer Learning

اخیراً، روش‌های مبتنی بر خودرمزگذار به دلیل مزایایی نظیر عدم نیاز به داده‌های برچسب‌دار و سرعت همگرایی بالا، به‌طور گسترده در سیستم‌های توصیه‌گر مورد استفاده قرار گرفته‌اند. برخی از کارها از یک نیمه‌خودرمزگذار^{۱۹} برای تعبیه همزمان اطلاعات صفات آیتم و ویژگی‌های گراف آیتم‌ها جهت پیش‌بینی امتیاز استفاده می‌کنند تا نتایج را بهبود بخشند. با این وجود، این مدل‌ها همچنان با دو محدودیت و ایراد اساسی روبه‌رو هستند که باید برطرف شوند:

- ضعف در مقداردهی اولیه: این مدل‌ها در کاوش و بهبود مقداردهی اولیه برای بازنمایی ویژگی‌های پنهان نادیده گرفته می‌شوند. اکثر مدل‌های فعلی از یک رویکرد یکنواخت و ساده برای این مقداردهی استفاده می‌کنند که پتانسیل بهینه‌سازی و کارایی مدل را محدود می‌کند.
- فقدان تطبیق‌پذیری^{۲۰}: بسیاری از مدل‌های توصیه‌گر موجود فاقد تطبیق‌پذیری و کارایی لازم در انتقال اطلاعات جانبی کاربران یا آیتم‌ها برای گسترش فضای ویژگی^{۲۱} هستند.

۱.۴. معرفی راهکار پیشنهادی: مدل FSTD MF

برای مقابله با چالش‌های ذکر شده در مدل‌های پیشین، این مقاله یک مدل جدید با نام فاکتورگیری ماتریس عمیق از طریق انتقال زیرفضای ویژگی^{۲۲} یا به‌اختصار FSTD MF پیشنهاد می‌دهد. این مدل با ترکیب دو رویکرد مجزا، سعی در برطرف کردن محدودیت‌های مربوط به مقداردهی اولیه و استفاده از اطلاعات جانبی دارد.

به‌طور مشخص، این مقاله مدل نیمه‌خودرمزگذار را معرفی می‌کند تا ویژگی‌های آیتم را مستقیماً از روی ماتریس امتیاز کاربر-آیتم مقداردهی اولیه کند. با ادغام این مقداردهی در مدل FSTD MF، فرایند یادگیری بازنمایی ویژگی‌های پنهان پیشرفته تسهیل می‌شود و مدل از پتانسیل بهینه‌سازی بسیار بالاتری نسبت به روش‌های مقداردهی تصادفی یا یکنواخت برخوردار می‌گردد.

همزمان، این کار یک جمله تنظیم‌کننده مبتنی بر فاصله تصویر بر روی زیرفضا^{۲۳} را به معماری خود اضافه می‌کند تا بازنمایی‌های ویژگی‌های پنهان مربوط به اطلاعات جانبی آیتم را به‌سمت وظیفه هدف^{۲۴} انتقال دهد. با این ابتکار، مدل FSTD MF مهارت بالایی در مهار اطلاعات جانبی از منابع متنوع به‌دست می‌آورد. این منابع می‌توانند شامل داده‌های صفات آیتم (مانند سال ساخت و ژانر) و همچنین اطلاعات امتیازدهی از دامنه‌های دیگر باشند. بنابراین، مدل پیشنهادی می‌تواند از اطلاعات جانبی به‌صورت کارآمدتری استفاده کند و تطبیق‌پذیری بسیار بهتری از خود نشان دهد.

مشارکت‌های اصلی^{۲۵} این مدل را می‌توان به‌صورت زیر خلاصه کرد:

¹⁹ Semi-Autoencoder

²⁰ Versatility

²¹ Feature Space

²² Deep Matrix Factorization via Feature Subspace Transfer

²³ Subspace Projection Distance

²⁴ Target Task

²⁵ Main Contributions

- تسهیل انتقال ویژگی^{۲۶}: برای حل مشکل عمومیت و کارایی پایین در انتقال اطلاعات جانبی، این مقاله از فاصله تصویر بر روی زیرفضا میان ویژگی پنهان اطلاعات جانبی آیتم و ویژگی پنهان خود آیتم، به عنوان یک جمله جریمه^{۲۷} استفاده می کند تا فرایند انتقال ویژگی به شکل موثری محقق شود.
- مقداردهی اولیه هوشمند: برای غلبه بر محدودیت های ناشی از روش های ساده و یکنواخت مقداردهی اولیه، مدل پیشنهادی از نیمه خودرمزگذار بهره می برد و با ادغام آن در ساختار DMF، بازنمایی های قدرتمندتری به دست می آورد که در نهایت عملکرد سیستم توصیه گر را بهبود می بخشد.
- بهبود دقت پیش بینی: در مقایسه با مدل پایه فاکتورگیری ماتریس عمیق، مدل پیشنهادی قادر است خطای مطلق میانگین و جذر میانگین مربعات خطا را تا ۶/۵ درصد بهبود ببخشد.

۱.۵. فرمول بندی ریاضی DMF

تکمیل ماتریس یکی از روش های متداول فاکتورگیری ماتریس است. فرض رتبه پایین^{۲۸} در روش های سنتی تکمیل ماتریس نشان می دهد که ماتریس امتیازات جزئی مشاهده شده (ماتریس R) از یک مدل متغیر پنهان خطی^{۲۹} نشأت می گیرد. این رابطه را می توان به صورت زیر نشان داد:

$$R = UV^T$$

در این رابطه، U نمایانگر بازنمایی ویژگی های پنهان کاربران و V بازنمایی ویژگی های پنهان آیتم ها است. برای یافتن این ماتریس ها، تابع هدف استاندارد به شکل زیر تعریف می شود:

$$\min_{U,V} \|\Psi \odot (R - UV^T)\|_F^2 + \lambda \|V\|_F^2 + \beta \|U\|_F^2$$

در معادله بالا، Ψ یک ماتریس باینری است که درایه های آن اگر امتیازی مشاهده شده باشد برابر ۱ و در غیر این صورت صفر است. همچنین λ و β پارامترهای تنظیم سازی^{۳۰} هستند و نماد $\odot$ ضرب هادامارد^{۳۱} (ضرب درایه به درایه) را نشان می دهد. با کمینه سازی این تابع، می توان درایه های گم شده^{۳۲} ماتریس را بازیابی کرد.

با این حال، محققان برای غلبه بر محدودیت های مدل های خطی، پیشنهاد دادند که از شبکه های عصبی چندلایه برای یادگیری بازنمایی ویژگی های پنهان کاربران یا آیتم ها استفاده شود تا مدل های متغیر پنهان غیرخطی تقریب زده شوند. در این رویکرد جدید، تابع هدف به صورت زیر جایگزین می شود:

$$\min_{V,W,b} \frac{1}{2n} \sum_{i=1}^n \|\Psi_i \odot (r_i - g(W\hat{v}_i + b))\|^2 + \frac{1}{2n} \lambda \|V\|_F^2 + \frac{1}{2} \beta \|W\|_F^2$$

²⁶ Feature Transfer

²⁷ Penalty Term

²⁸ Low-rank Assumption

²⁹ Linear Latent Variable Model

³⁰ Regularization Parameters

³¹ Hadamard Product

³² Missing Entries

در این معادله، W ماتریس وزن‌ها، b بردار سوگیری^{۳۳}، Ψ_i ستون λ م از ماتریس Ψ ، $\hat{v}_i$ ستون λ م از ماتریس V^T ، r_i ستون λ م از ماتریس R و $g(\cdot)$ تابع فعال‌ساز^{۳۴} (مانند تابع سیگموئید^{۳۵} یا تانژانت هذلولوی) است.

از آنجا که به‌خوبی می‌دانیم شبکه‌های عصبی چندلایه معمولاً در تقریب توابع غیرخطی بسیار موثرتر از شبکه‌های عصبی تک‌لایه عمل می‌کنند، تابع هدف نهایی برای یک شبکه با K لایه پنهان می‌تواند به‌شکل زیر تقریب زده و بسط داده شود:

$$\min_{V,W,b} \frac{1}{2n} \sum_{i=1}^n ||\Psi_i \odot (r_i - g^{(K+1)}(g^{(K)}(\dots g^{(1)}(\hat{v}_i, \theta^{(1)}), \dots, \theta^{(K)}), \theta^{(K+1)}))||^2 \\ + \frac{1}{2n} \lambda ||V||_F^2 + \frac{1}{2} \beta \sum_{j=1}^{K+1} ||W^{(j)}||_F^2$$

در این فرمول تعمیم‌یافته، نماد $\theta^{(j)}$ دربرگیرنده وزن‌ها و سوگیری‌های لایه λ م است. با حل این معادله پیچیده، ماتریس V (ویژگی‌های پنهان آیتم‌ها) به‌دست می‌آید و سپس می‌توان تمامی درایه‌های ازدست‌رفته در ماتریس R را بازیابی و پیش‌بینی کرد.

۱.۶. ترکیب مدل DMF با نیمه‌خودرمزگذار

در مدل پایه DMF، مقداردهی اولیه بازنمایی ویژگی پنهان V با استفاده از توزیع گاوسی^{۳۶} ساخته می‌شود. این امر می‌تواند قابلیت یادگیری مدل را محدود کند و دستیابی به یک بازنمایی ویژگی پنهان بهتر را دشوار سازد. برای حل این مشکل، مقاله حاضر یک نیمه‌خودرمزگذار را با مدل DMF ترکیب می‌کند تا قابلیت یادگیری بهبود یابد.

نیمه‌خودرمزگذار یک مدل بدون نظارت^{۳۷} است که تلاش می‌کند یک بازنمایی فشرده از ورودی را در لایه خروجی یاد بگیرد. این مدل عموماً از یک شبکه سه‌لایه تشکیل شده است و نیازی ندارد که ابعاد لایه ورودی و لایه خروجی برابر باشند. با فرض این‌که ورودی به‌صورت $\{x_1, x_2, \dots, x_n\}$ باشد (که در آن $x_i \in R^m$)، نیمه‌خودرمزگذار سعی می‌کند تابعی مانند $x \approx f_{Q,p}(x)$ را یاد بگیرد. رمزگذار و رمزگشای یک نیمه‌خودرمزگذار به‌صورت زیر بیان می‌شوند:

$$\xi_i = f(Qx_i + p)$$

$$\tilde{x}_i = g(\tilde{Q}\xi_i + \tilde{p})$$

در این روابط، Q و $\tilde{Q}$ ماتریس‌های وزن، p و $\tilde{p}$ بردارهای سوگیری، ξ_i خروجی رمزگذار، $\tilde{x}_i$ نتیجه بازسازی x_i و f و g توابع فعال‌ساز غیرخطی هستند. هدف مدل نیمه‌خودرمزگذار، کمینه‌سازی خطای بازسازی^{۳۸} از طریق یادگیری پارامترهای Q ، p ، $\tilde{Q}$ و $\tilde{p}$ است:

$$\min_{Q,\tilde{Q},p,\tilde{p}} \sum_{i=1}^n ||x_i - \tilde{x}_i||^2 = \min_{Q,\tilde{Q},p,\tilde{p}} \sum_{i=1}^n ||x_i - g(\tilde{Q}(f(Qx_i + p)) + \tilde{p})||^2$$

³³ Bias Vector

³⁴ Activation Function

³⁵ Sigmoid Function

³⁶ Gaussian Distribution

³⁷ Unsupervised Model

³⁸ Reconstruction Error

نیمه خود رمزگذارها استفاده گسترده‌ای در سیستم‌های توصیه‌گر پیدا کرده‌اند و نتایج امیدوارکننده‌ای داشته‌اند. در این مقاله، از نیمه خود رمزگذار صرفاً برای استخراج بازنمایی ویژگی پنهان V استفاده می‌شود و برای پیش‌بینی خروجی کاربردی ندارد. تابع سیگموئید به عنوان تابع فعال‌ساز رمزگذار اعمال می‌شود و این فرایند را می‌توان به شکل زیر بیان کرد:

$$\hat{v}_i = f(Qr_i + p)$$

با ادغام این مقداردهی اولیه در مدل DMF، مقداردهی بهتری برای بازنمایی ویژگی پنهان V به دست می‌آید. در نهایت، نتایج پیش‌بینی با حل تابع هدف بسط داده شده مدل DMF (که در بخش پیشین ذکر شد) استخراج می‌شوند. با این حال، تکیه صرف بر داده‌های امتیازدهی، کارایی پیش‌بینی مدل را محدود می‌کند، به ویژه زمانی که ماتریس امتیازات پراکنده است.

برای کاهش این مشکل، معرفی فاصله تصویر بر روی زیرفضا برای ترکیب اطلاعات جانبی پیشنهاد شده است.

۱.۷. مدل DMF از طریق انتقال زیرفضای ویژگی

با فرض این که بازنمایی ویژگی پنهان V_A از اطلاعات جانبی به دست آمده باشد، می‌توان این ویژگی پنهان را به دامنه هدف^{۳۹} انتقال داد. به طور کلی، یک جمله تنظیم‌سازی^{۴۰} به نام $\text{Sim}(V, V_A)$ می‌تواند به مدل بهینه‌سازی اضافه شود تا ویژگی‌های کمکی V_A را انتقال دهد. این جمله، معیاری برای نشان دادن شباهت میان V و V_A است.

در این مقاله، از فاصله تصویر بر روی زیرفضا برای اندازه‌گیری این شباهت استفاده می‌شود. اگر ستون i ام از V را با v_i نشان دهیم، فاصله تصویر از v_i تا زیرفضای پوشش داده شده^{۴۱} توسط V_A به صورت زیر تعریف می‌شود:

$$\text{dist}(v_i, V_A) = \|v_i - V_A V_A^T v_i\|_F$$

که در آن V_A یک ماتریس نیمه متعامد^{۴۲} است. بر این اساس، شباهت $\text{Sim}(V, V_A)$ به شکل زیر تعریف می‌گردد:

$$\text{Sim}(V, V_A) = \sum_{i=1}^n \text{dist}^2(v_i, V_A) = \sum_{i=1}^n \|v_i - V_A V_A^T v_i\|_F^2 = \|V - V_A V_A^T V\|_F^2 = \|V\|_F^2 - \|V_A V_A^T V\|_F^2$$

با اضافه کردن این میزان شباهت به عنوان یک جمله جریمه به مدل پایه (معادله بسط داده شده DMF در بخش‌های پیشین)، تابع هدف نهایی شکل می‌گیرد. این تابع هدف با در نظر گرفتن پارامتر اطمینان^{۴۳} $\eta \in [0, 1]$ ساده‌سازی می‌شود.

پارامتر η میزان ارتباط میان اطلاعات جانبی و داده‌های هدف را نشان می‌دهد. یک η بزرگ به این معنی است که دامنه کمکی و دامنه هدف ساختار ویژگی مشابهی دارند. در مقابل، اگر $\eta = 0$ باشد، مدل به همان شبکه DMF پایه کاهش می‌یابد که نشان می‌دهد داده‌های کمکی نمی‌توانند عملکرد پیش‌بینی دامنه هدف را بهبود بخشند.

³⁹ Target Domain

⁴⁰ Regularization Term

⁴¹ Spanned Subspace

⁴² Partial Orthonormal Matrix

⁴³ Confidence Parameter

مسئله بهینه‌سازی این مدل پیشنهادی (FSTD MF) از نوع غیرمحدب^{۴۴} است. برای یافتن کمینه‌های محلی^{۴۵}، از تکنیک‌های بهینه‌سازی غیرخطی استفاده می‌شود. به‌طور مشخص، برای ماتریس‌های نسبتاً کوچک (مثلاً ابعاد کمتر از ۱۰۰۰) از الگوریتم BFGS و برای مسائل مقیاس‌بزرگ^{۴۶} از الگوریتم انتشار پس‌رو مقاوم بهبودیافته^{۴۷} (iRprop+) استفاده می‌گردد تا کارایی بهینه‌سازی تضمین شود.

۱.۸. یادگیری بازنمایی‌های پنهان از اطلاعات جانبی آیتم‌ها

همان‌طور که پیش‌تر اشاره شد، مدل پیشنهادی، اطلاعات جانبی ارائه‌شده آیتم‌ها (ماتریس A) را پردازش می‌کند تا بازنمایی ویژگی پنهان آن‌ها یعنی V_A را به‌دست آورد. برای این منظور، دو متدولوژی متمایز به‌کار گرفته می‌شود. اطلاعات جانبی آیتم‌ها معمولاً در دو دسته قرار می‌گیرند: اطلاعات ضمنی آیتم (مانند صفات، تصاویر، نظرات و ویدئوها) و ماتریس‌های امتیازدهی که آیتم‌ها را در دامنه‌های مختلف ارزیابی می‌کنند. از آنجا که به‌دست آوردن اطلاعاتی نظیر تصاویر و ویدئوها می‌تواند چالش‌برانگیز باشد، این پژوهش از اطلاعات صفات آیتم^{۴۸} و ماتریس‌های امتیازدهی دامنه خاص که دسترسی به آن‌ها آسان‌تر است، استفاده می‌کند. به‌طور دقیق‌تر، هر آیتم دارای داده‌های صفاتی مانند سال تولید و ژانر است. با توجه به اینکه دسته‌های متعددی در هر صفت وجود دارد، این مقاله برای مدیریت داده‌های صفات آیتم‌ها از روش کدگذاری وان-هات^{۴۹} استفاده می‌کند. به‌عنوان مثال، در مجموعه‌داده MovieLens، هر بازه ۷ ساله به‌عنوان یک کد متمایز برای صفت سال در نظر گرفته می‌شود و هر ژانر نیز یک کد مجزا برای صفت ژانر دارد. پس از کدگذاری، داده‌ها به‌صورت ماتریس $C \in \mathbb{R}^{n \times d}$ نشان داده می‌شوند. از آنجا که این ماتریس متعامد^{۵۰} نیست، گام بعدی متعامدسازی آن است. در نهایت، پس از این مرحله، بازنمایی ویژگی پنهان V_A از اطلاعات جانبی آیتم‌ها به‌دست می‌آید. شایان ذکر است که رویکرد دوم در این مقاله، برای استخراج ویژگی از ماتریس‌های امتیازدهی در دامنه‌های دیگر با استفاده از متدولوژی‌های پیشنهاد متقاطع-دامنه^{۵۱} طراحی شده است. با توجه به تمرکز و محدوده تعریف‌شده برای پیاده‌سازی این معماری که صرفاً بر روی تنظیمات اطلاعات-صفات-آیتم متمرکز است، از بسط و بررسی پیچیدگی‌های محاسباتی مربوط به وظایف متقاطع-دامنه صرف‌نظر می‌شود.

۱.۹. استخراج ویژگی از ماتریس امتیازات در دامنه‌های دیگر

برخلاف استخراج ویژگی‌های پنهان از صفات آیتم‌ها (که با کدگذاری وان-هات انجام می‌شود)، زمانی که صحبت از ماتریس‌های امتیازدهی آیتم‌ها در دامنه‌های دیگر به‌میان می‌آید، از یک مدل یادگیری ویژگی^{۵۲} استفاده می‌شود. این رویکرد یادآور روش‌های پیشنهاد متقاطع-دامنه است.

⁴⁴ Non-convex

⁴⁵ Local Minima

⁴⁶ Large-scale Problems

⁴⁷ Improved Resilient Backpropagation (iRprop+)

⁴⁸ Item Attributes

⁴⁹ One-hot Encoding

⁵⁰ Orthogonal

⁵¹ Cross-domain Recommendation

⁵² Feature Learning Model

برخی از پژوهش‌های پیشین از یک نیمه‌خودرمزگذار برای تعبیه مشترک^{۵۳} صفات آیتم با ویژگی‌های گراف آن‌ها استفاده کرده‌اند تا پیش‌بینی دقیق‌تری از امتیازات داشته باشند. در این روش، امتیازات آیتم‌ها (ماتریس R)، صفات آیتم‌ها (ماتریس A) و ساختارهای گراف آیتم‌ها (ماتریس G) به یکدیگر متصل شده و به نیمه‌خودرمزگذار داده می‌شوند تا بازنمایی‌های پنهان آیتم یاد گرفته شود:

$$\epsilon = f(Q_{\text{con}}(R, A, G) + p)$$

در این معادله، $\epsilon \in \mathbb{R}^{n \times d}$ نمایانگر بازنمایی ویژگی‌های پنهانی است که باید یاد گرفته شوند. در زمینه این مقاله، از آنجا که ماتریس‌های A و G دارای حشو (افزونگی) هستند، معادله بالا به شکل ساده‌شده زیر تقلیل می‌یابد:

$$\epsilon = f(QR + p)$$

این ساختار شباهت زیادی به یک نیمه‌خودرمزگذار استاندارد دارد. بنابراین، با حل معادله خطای بازسازی (که در بخش‌های پیشین معرفی شد)، ویژگی‌های پنهان از ماتریس‌های امتیازدهی در دامنه‌های خارجی استخراج می‌شوند. پس از انجام فرایند تنظیم‌سازی و متعامدسازی، بازنمایی ویژگی پنهان V_A برای دامنه‌های دیگر به دست می‌آید.

۱.۱۰. جمع‌بندی: ساختار کلی مدل FSTDMF

با در کنار هم قرار دادن تمامی اجزای ریاضی و ساختاری شرح داده‌شده، می‌توان چارچوب نهایی مدل پیشنهادی FSTDMF را ترسیم کرد. جریان کلی اطلاعات در این معماری شامل مراحل زیر است:

- مقداردهی اولیه: مدل ابتدا ماتریس امتیازات را به عنوان ورودی یک شبکه نیمه‌خودرمزگذار دریافت می‌کند تا بازنمایی ویژگی پنهان آیتم‌ها (V) را مقداردهی اولیه کند.
- پردازش اطلاعات جانبی: همزمان، مدل با استفاده از دو روش متمایز (کدگذاری وان-هات برای صفات و مدل نیمه‌خودرمزگذار برای دامنه‌های خارجی) اطلاعات جانبی آیتم‌ها (A) را پردازش کرده و بازنمایی ویژگی پنهان آن‌ها (V_A) را استخراج می‌کند.
- انتقال ویژگی‌ها: ماتریس ویژگی اولیه (V) که از نیمه‌خودرمزگذار به دست آمده، به عنوان ورودی به شبکه‌های عمیق DMF تغذیه می‌شود. در همین حین، جمله تنظیم‌کننده مبتنی بر فاصله تصویر بر روی زیرفضا به تابع هدف مدل اضافه می‌شود تا ویژگی‌های سودمند را از V_A به V منتقل کند.
- پیش‌بینی نهایی: با بهینه‌سازی این تابع هدف ترکیبی، یک ماتریس ویژگی V برتر و غنی‌شده به دست می‌آید که در نهایت منجر به بهبود دقت در پیش‌بینی امتیازات کاربر-آیتم می‌گردد.

⁵³ Co-embed

فصل دوم – پاسخ به سوالات تئوری

۲.۱. مسئله اصلی پژوهش و ضعف‌های رویکردهای موجود

مسئله اصلی که این مقاله به آن پرداخته است چیست و قصد دارد بر کدام دو ضعف مشخص در رویکردهای موجود فاکتورگیری ماتریس عمیق غلبه کند؟ توضیح دهید که چرا این ضعف‌ها برای عملکرد سیستم توصیه‌گر حائز اهمیت هستند.

مسئله محوری این مقاله، غلبه بر مشکل پراکندگی داده‌ها در سیستم‌های توصیه‌گر است. اگرچه روش‌های پالایش مشارکتی و فاکتورگیری ماتریس کاربرد گسترده‌ای دارند، اما زمانی که با داده‌های خلوت و پراکنده مواجه می‌شوند، کارایی آن‌ها به شدت کاهش می‌یابد و این موضوع یک گلوگاه^{۵۴} مهم برای آن‌ها محسوب می‌شود. این مقاله به دنبال این است که با استفاده از مدل‌سازی غیرخطی عمیق و بهره‌گیری از اطلاعات کمکی بر این گلوگاه غلبه کند.

نویسندگان مقاله به‌طور مشخص به دو محدودیت اصلی در مدل‌های پیشین (حتی مدل‌های مبتنی بر یادگیری عمیق) اشاره می‌کنند که باید برطرف شوند:

- ضعف اول – رویکرد یکنواخت و ساده در مقداردهی اولیه^{۵۵}: اکثر مدل‌های فعلی از روش‌های ساده و یکپارچه (مانند استفاده از توزیع گاوسی) برای مقداردهی اولیه بازنمایی‌های ویژگی پنهان استفاده می‌کنند.
- ضعف دوم – عدم تطبیق‌پذیری و کارایی در انتقال اطلاعات کمکی: بسیاری از مدل‌های توصیه‌گر موجود در انتقال اطلاعات کمکی کاربران یا آیتم‌ها برای گسترش فضای ویژگی، فاقد کارایی و تطبیق‌پذیری لازم هستند. این روش‌ها معمولاً فقط برای یک نوع خاص از داده‌ها سفارشی‌سازی شده‌اند (مثلاً فقط برای اطلاعات جانبی خود آیتم یا فقط برای انتقال امتیازات از دامنه‌های دیگر) و نمی‌توانند به‌طور هم‌زمان و منعطف از منابع مختلف استفاده کنند.

مقاله توضیح می‌دهد که چرا برطرف نکردن این دو ضعف، مستقیماً دقت سیستم‌های توصیه‌گر را پایین می‌آورد:

- تأثیر ضعف اول (مقداردهی اولیه نامناسب): نحوه مقداردهی اولیه، تأثیر قابل توجهی بر عملکرد نهایی شبکه در فاکتورگیری ماتریس عمیق دارد. استفاده از توزیع‌های تصادفی ساده (مانند گاوسی)، ظرفیت یادگیری مدل و پتانسیل بهینه‌سازی آن را محدود می‌کند. این امر باعث می‌شود مدل نتواند به یک بازنمایی پنهان قدرتمند و بهینه دست یابد و در نتیجه در کشف الگوهای پیچیده سلیقه کاربران ناکام می‌ماند.
- تأثیر ضعف دوم (انتقال ناکارآمد اطلاعات کمکی): تکیه کردن صرف بر داده‌های ماتریس امتیازات، اثربخشی پیش‌بینی مدل را به شدت محدود می‌کند؛ به‌ویژه زمانی که این ماتریس خلوت باشد. از آنجا که مدل‌های پیشین فاقد تطبیق‌پذیری هستند، نمی‌توانند به‌طور یکپارچه و بهینه از منابع متنوع اطلاعاتی (مثل ترکیب ویژگی‌های درونی با امتیازات دامنه‌های خارجی) استفاده کنند تا فضاهای خالی ماتریس را پر کنند. در نتیجه، سیستم از اطلاعات ارزشمندی که می‌توانستند مشکل پراکندگی داده‌ها را حل کنند محروم می‌ماند و توصیه‌های نادقیقی ارائه می‌دهد.

⁵⁴ Bottleneck

⁵⁵ Initialization

۲.۲. معماری مقداردهی اولیه و مکانیزم انتقال زیرفضای ویژگی

چه معماری شبکه‌ای برای مقداردهی اولیه ویژگی‌های پنهان آیت‌ها استفاده می‌شود و چه ویژگی ساختاری آن را از یک رمزگذار خودکار استاندارد^{۵۶} متمایز می‌کند؟ همچنین، مکانیزمی را که مدل FSTD MF برای انتقال ویژگی‌های کمکی به وظیفه هدف استفاده می‌کند، توضیح دهید. شهود ریاضی نهفته در پس عبارت جریمه را نیز بیان کنید.

در مقاله، معماری مدل و نحوه انتقال اطلاعات با دقت ریاضی بالایی طراحی شده است.

برای مقداردهی اولیه به ویژگی‌های پنهان آیت‌ها از معماری شبکه‌ای به نام نیمه‌خودرمزگذار استفاده شده است. نکته بسیار کلیدی در این معماری این است که از نیمه‌خودرمزگذار صرفاً و منحصرأً به عنوان یک ابزار استخراج ویژگی^{۵۷} جهت یافتن نقطه شروع و مقداردهی اولیه استفاده می‌شود و هدف آن بازسازی کامل ورودی یا پیش‌بینی نهایی امتیازات در سیستم توصیه‌گر نیست. در شبکه‌های رمزگذار خودکار استاندارد، یک محدودیت سختگیرانه وجود دارد که بر اساس آن، لایه ورودی و لایه خروجی شبکه باید ابعاد کاملاً برابری داشته باشند. اما ویژگی ساختاری متمایزکننده‌ای که در مدل نیمه‌خودرمزگذار وجود دارد، این است که این محدودیت برابری ابعاد را می‌شکند. به عبارت دیگر، این شبکه نیازی ندارد که تعداد گره‌های لایه ورودی با تعداد گره‌های لایه خروجی آن یکسان باشد که این امر انعطاف‌پذیری فوق‌العاده‌ای برای پردازش داده‌هایی با ابعاد مختلف (مثل فشردسازی یک ماتریس بزرگ به یک فضای ویژگی کوچک‌تر) فراهم می‌کند.

مدل پیشنهاد شده (FSTD MF) برای انتقال دانش نهفته در اطلاعات جانبی به وظیفه هدف (که همان پیش‌بینی امتیازات کاربران است) از یک مکانیزم انتقال زیرفضا استفاده می‌کند. روند کار به این شکل است که ابتدا مدل اطلاعات کمکی آیت‌ها (مانند ژانر و سال ساخت یا ماتریس امتیازات همان فیلم در یک سایت دیگر) را دریافت کرده و یک بازنمایی پنهان از آن‌ها (با نماد V_A) می‌سازد. سپس برای تزریق این اطلاعات به شبکه اصلی از یک معیار ریاضی به نام فاصله تصویرسازی زیرفضا به عنوان عبارت جریمه در تابع بهینه‌سازی خود بهره می‌برد. این مکانیزم ویژگی‌های اصلی در حال آموزش شبکه (با نماد V) را مجبور می‌کند تا ساختار فضایی خود را با ویژگی‌های کمکی (V_A) همسو و تنظیم کنند.

برای درک منطق ریاضی این عبارت ابتدا باید بدانیم که ماتریس V_A به گونه‌ای استخراج می‌شود که متعامد جزئی باشد (یعنی $V_A^T V_A = E$). در جبر خطی، عبارت $V_A V_A^T v_i$ نشان‌دهنده تصویر بردار ویژگی هدف (v_i) بر روی زیرفضایی است که توسط ویژگی‌های کمکی (V_A) ایجاد شده است. فاصله این دو فضا برای یک ستون به شکل زیر تعریف می‌شود:

$$\text{dist}(v_i, V_A) = \|v_i - V_A V_A^T v_i\|_F$$

با بسط دادن این فرمول برای کل ماتریس ویژگی‌ها (V) عبارت شباهت (که همان عبارت جریمه است) به این شکل نهایی محاسبه می‌شود:

$$\text{Sim}(V, V_A) = \|V\|_F^2 - \|V_A V_A^T V\|_F^2$$

⁵⁶ Standard Autoencoder

⁵⁷ Feature Extraction

این فرمول در حال محاسبه فاصله هندسی و ریاضی بین ویژگی‌های پنهان مدل ما و تصویر این ویژگی‌ها روی فضای اطلاعات کمکی است. وقتی این عبارت به عنوان یک جریمه به تابع خطای کل شبکه اضافه می‌شود، الگوریتم بهینه‌سازی سعی می‌کند این فاصله را به حداقل برساند. در نتیجه این فرمول یک کشش ریاضی قدرتمند ایجاد می‌کند که باعث می‌شود ماتریس V به جای اینکه به صورت کاملاً تصادفی شکل بگیرد مجبور شود تا ساختار و دانش نهفته در اطلاعات کمکی (V_A) را به خود جذب کند.

۲.۳. نقش و تحلیل پارامتر اطمینان در مدل پیشنهادی

نقش پارامتر اطمینان η در FSTDMF را بررسی کنید. هنگامی که $\eta = 0$ است، مدل به چه چیزی تقلیل می‌یابد و چرا بر اساس آزمایش‌ها مقدار $\eta = 1$ بهینه است؟

پارامتر اطمینان η نقش یک عامل موازنه^{۵۸} را در تابع هدف مدل ایفا می‌کند. این پارامتر که مقداری در بازه $[0, 1]$ دارد، میزان ارتباط و وابستگی بین اطلاعات کمکی و داده‌های هدف را تعیین می‌کند.

در واقع این پارامتر به الگوریتم یادگیری می‌گوید که چقدر باید به اطلاعات جانبی استخراج شده اعتماد کند و تا چه حد اجازه دارد ساختار ویژگی‌های پنهان مدل اصلی را تحت تأثیر این اطلاعات خارجی قرار دهد. مقادیر بزرگتر برای η نشان‌دهنده این فرض است که دامنه کمکی و دامنه هدف دارای ساختار ویژگی بسیار مشابهی هستند و مدل باید به شدت از اطلاعات خارجی برای تنظیم وزن‌های خود استفاده کند.

زمانی که پارامتر η برابر با صفر تنظیم شود، عبارت مربوط به انتقال زیرفضای ویژگی (عبارت جریمه یا همان فاصله تصویرسازی زیرفضا) به طور کامل در فرمول تابع هدف صفر شده و از تابع بهینه‌سازی مدل حذف می‌شود. با حذف این عبارت، مدل پیشنهادی FSTDMF مستقیماً به فرمول پایه تقلیل می‌یابد. این بدان معناست که در این حالت، مدل دقیقاً تبدیل به یک مدل استاندارد فاکتورگیری ماتریس عمیق می‌شود که صرفاً از یک نیمه خودرمزگذار برای مقداردهی اولیه ویژگی‌های خود استفاده کرده است و در طول فرایند آموزش، هیچ‌گونه انتقال دانشی از دامنه کمکی به دامنه هدف صورت نمی‌گیرد. به همین دلیل، طبق مشاهدات مقاله، زمانی که مقدار این پارامتر به صفر نزدیک می‌شود دقت پیش‌بینی سیستم به شدت کاهش می‌یابد.

آزمایش‌های بررسی حساسیت پارامترها نشان دادند که با افزایش یکنواخت مقدار η ، خطای سیستم (MAE و RMSE) به طور پیوسته کاهش می‌یابد و مدل در نقطه $\eta = 1$ به بالاترین سطح دقت خود می‌رسد. نویسندگان مقاله دو دلیل اصلی برای این پدیده بیان می‌کنند:

- در آزمایش‌های طراحی شده توسط پژوهشگران، دامنه هدف و دامنه کمکی ارتباط بسیار شدیدی با یکدیگر داشتند (به عنوان مثال هر دو شامل داده‌های امتیازدهی کاربران به فیلم‌ها در پلتفرم‌های مشابه بودند).
- چون ماهیت داده‌های خارجی و داخلی از یک جنس بود، هرچه مدل بیشتر و با وزن بالاتری (نزدیک به ۱) از اطلاعات استخراج شده دامنه کمکی تقلب می‌گرفت، دانش بهتر و دقیق‌تری درباره آیت‌ها کسب می‌کرد. در نتیجه دادن بیشترین ضریب تأثیر به اطلاعات کمکی باعث شد تا مدل بتواند بر مشکل پراکندگی داده‌ها به بهترین شکل ممکن غلبه کند و کمترین میزان خطا را ثبت نماید.

⁵⁸ Trade-off Parameter

۲.۴. معیارهای ارزیابی و بررسی بهبود عملکرد مدل

معیارهای ارزیابی استفاده شده را مشخص کنید و بهبود کمی برجسته‌ای را که مدل FSTDMF نسبت به DMF استاندارد به دست آورده است خلاصه کنید. همچنین شرایطی را که تحت آن حداکثر میزان پیشرفت رخ داده است بیان کنید.

برای سنجش دقت و ارزیابی عملکرد مدل‌های مورد بررسی، پژوهشگران از دو معیار استاندارد و بسیار رایج در حوزه سیستم‌های توصیه‌گر استفاده کرده‌اند:

- خطای مطلق میانگین (MAE یا Mean Absolute Error)
- ریشه میانگین مربعات خطا (RMSE یا Root Mean Square Error)

این دو معیار اختلاف و انحراف بین امتیاز پیش‌بینی شده توسط الگوریتم و امتیاز واقعی ثبت شده توسط کاربر را اندازه‌گیری می‌کنند. طبیعتاً هرچه مقادیر به دست آمده برای MAE و RMSE کمتر باشد، نشان‌دهنده خطای کمتر و دقت بالاتر مدل در پیش‌بینی است.

مدل پیشنهادی این پژوهش (FSTDMF) توانسته است یک برتری کمی کاملاً واضح نسبت به مدل پایه خود یعنی فاکتورگیری ماتریس عمیق به ثبت برساند. دستاورد اصلی این است که مدل پیشنهادی موفق شده در بهترین حالت، بهبود ۶/۵ درصدی را به طور هم‌زمان در هر دو معیار خطای MAE و RMSE نسبت به مدل کلاسیک DMF ایجاد کند.

این رکورد بالاترین میزان پیشرفت (یعنی همان بهبود ۶/۵ درصدی) در یک سناریو و شرایط آزمایشی خاص به دست آمده است. طبق تحلیل‌های ارائه شده، این حداکثر بهره‌وری تحت شرایط زیر رخ داده است:

- زمانی که مدل روی وظیفه انتقال دانش در مجموعه داده ترکیبی DoubanMovie-MovieLens20M در حال آزمایش بود.
- زمانی که اندازه مجموعه آموزشی^{۵۹} به کمترین حالت خود یعنی ۳۰ درصد کاهش یافته بود.

مقاله دلیل ثبت این پیشرفت بزرگ در چنین شرایط سختی (داده‌های بسیار کم) را این‌گونه توجیه می‌کند که مدل FSTDMF توانسته است ویژگی‌های پنهان آیت‌ها را به شکلی بسیار کارآمد از یک ماتریس امتیازات کمکی استخراج کند. نکته اینجاست که مقیاس امتیازدهی در سایت DoubanMovie با MovieLens متفاوت است. در روش‌های متداول انتقال یادگیری، این اختلاف مقیاس معمولاً باعث شکست مدل می‌شود؛ اما استفاده مدل پیشنهادی از مکانیزم فاصله تصویر بر روی زیرفضا، تأثیر مخرب این تفاوت مقیاس‌ها را کاملاً خنثی می‌کند. دلیل این خنثی‌سازی آن است که مکانیزم تصویرسازی زیرفضا، به جای تمرکز بر مقادیر مطلق و عددی امتیازات، بر هم‌راستایی ساختاری و هندسی^{۶۰} تمرکز دارد. با متعامدسازی ماتریس ویژگی‌های جانبی و محاسبه فاصله تصویر، سیستم تنها الگوهای رابطه‌ای و دانش نهفته در رفتار کاربران را استخراج می‌کند که مستقل از مقیاس اولیه است. در

⁵⁹ Training Set

⁶⁰ Structural Alignment

نتیجه مدل پیشنهادی حتی با داشتن تنها ۳۰ درصد از داده‌های آموزشی، با استفاده هوشمندانه از اطلاعات هندسی یک دامنه دیگر، خطای خود را به شدت کاهش داده است.

۲.۵. مطالعه فرسایشی (حذف اجزا) و تأثیر ابعاد داده‌ها

۵- مقاله یک مطالعه حذف اجزا^{۶۱} با جداسازی دو جزء اصلی انجام می‌دهد. این دو جزء (همراه با نام‌های اختصاری آن‌ها) چه هستند و این مطالعه درباره میزان مشارکت نسبی آن‌ها در مجموعه داده‌های کوچک در مقایسه با مجموعه داده‌های بزرگ چه چیزی را نشان داد؟

مقاله برای انجام مطالعه حذف اجزا هسته مرکزی مدل پیشنهادی خود را به دو جزء مستقل زیر تفکیک کرده است:

- انتقال زیرفضای ویژگی که با نام اختصاری FST (Feature Subspace Transfer) شناخته می‌شود.
- نیمه خودرمزگذار که با نام اختصاری SA (Semi-autoencoder) معرفی شده است.

آزمایش‌های انجام شده روی چهار مجموعه داده مختلف نشان داد که اضافه شدن هر یک از این اجزا به تنهایی عملکرد مدل پایه (DMF) را بهبود می‌بخشد، اما میزان مشارکت آن‌ها بسته به ابعاد مجموعه داده خیلی متفاوت است:

- در مجموعه داده‌های کوچک‌تر (مانند MovieLens100k و MovieLens1M-MovieLens100k) نتایج نشان داد که مدل مجهز به انتقال ویژگی یعنی DMF (+FST) عملکرد بهتری نسبت به مدل مجهز به نیمه خودرمزگذار یعنی DMF (+SA) دارد. این موضوع نشان می‌دهد قابلیت انتقال زیرفضای ویژگی (FST) برای مجموعه داده‌های کوچک بسیار موثر و سودمند است. دلیل این امر آن است که وقتی داده‌ها محدود هستند، مدل به شدت از دریافت دانش و اطلاعات جانبی از دامنه‌های دیگر سود می‌برد تا کمبود داده‌های خود را جبران کند.
- از سوی دیگر در مجموعه داده‌های بزرگ (مانند MovieLens1M و DoubanMovie-MovieLens20M) شرایط متفاوت بود. اگرچه در این داده‌ها نیز مدل DMF (+FST) باعث کاهش خطا و بهبود عملکرد شد، اما میزان این بهبود اختلاف قابل توجهی با عملکرد مدل DMF (+SA) نداشت. این یافته دلالت بر آن دارد که هنگام کار با مجموعه داده‌های بزرگ اما خلوت، صرفاً استفاده از الگوریتم نیمه خودرمزگذار (SA) برای مقداردهی اولیه بازنمایی ویژگی‌های پنهان می‌تواند تقریباً به همان اندازه استراتژی پیچیده‌تر انتقال ویژگی موثر واقع شود. در واقع در داده‌های بزرگ، پیدا کردن یک نقطه شروع مناسب برای شبکه‌های عصبی به اندازه وارد کردن داده‌های خارجی اهمیت پیدا می‌کند.

با یک نگاه کلی به نتایج این ارزیابی مشخص شد که مدل یکپارچه FSTD MF (ترکیب هم‌زمان FST و SA) به‌طور پیوسته در تمامی حالت‌ها بهترین نتیجه را کسب می‌کند که این موضوع اثربخشی و ضرورت ادغام این دو مکانیزم را برای رسیدن به بالاترین دقت برجسته می‌سازد.

⁶¹ Ablation Study

فصل سوم – تشریح پیاده‌سازی عملی و ساختار کد

۳.۱. آماده‌سازی داده‌ها و استخراج ویژگی‌های جانبی

اولین گام حیاتی در پیاده‌سازی این سیستم توصیه‌گر، بارگذاری صحیح داده‌های خام و تبدیل آن‌ها به فرمت‌های ماتریسی قابل فهم برای شبکه‌های عصبی است. این وظیفه در کد توسعه داده شده توسط دو تابع مجزا با نام‌های `load_ml1m` و `load_ml100k` انجام می‌شود که به ترتیب مسئولیت پیش‌پردازش^{۶۲} دو مجموعه داده `MovieLens-1M` و `MovieLens-100K` را بر عهده دارند.

روند کلی این توابع شامل سه بخش اصلی است:

- استخراج ماتریس امتیازات (R): ابتدا فایل‌های حاوی تاریخچه امتیازات (مانند `u.data` و `ratings.dat`) خوانده می‌شوند. با توجه به تعداد کاربران و آیتم‌های یکتا، یک ماتریس صفر با ابعاد $(\text{num_users} \times \text{num_items})$ ایجاد می‌گردد. سپس با پیمایش سطر به سطر داده‌ها، امتیاز واقعی هر کاربر به هر فیلم در درایه مربوطه قرار می‌گیرد تا ماتریس خلوت امتیازات شکل بگیرد.
- کدگذاری ویژگی‌های جانبی (کدگذاری وان-هات): برای استخراج اطلاعات کمکی آیتم‌ها، فایل حاوی اطلاعات فیلم‌ها خوانده می‌شود. دو ویژگی کلیدی سال تولید و ژانرها مورد پردازش قرار می‌گیرند. از آنجا که سال تولید یک داده پیوسته است، ابتدا با استفاده از بازه‌های ۷ ساله گروه‌بندی^{۶۳} می‌شود و سپس با متد `pd.get_dummies` به بردارهای وان-هات تبدیل می‌گردد. برای ژانرها نیز که دارای چندین مقدار همزمان برای یک فیلم هستند، یک ماتریس باینری تشکیل می‌شود که وجود یا عدم وجود هر ژانر را با صفر و یک مشخص می‌کند.
- متعامدسازی ویژگی‌ها^{۶۴}: پس از ترکیب بردارهای وان-هات مربوط به سال و ژانر در قالب یک ماتریس یکپارچه (G)، این ماتریس باید شرایط ریاضی مقاله را برآورده سازد. طبق مبانی نظری، ماتریس ویژگی‌های کمکی (V_A) باید متعامد جزئی باشد. برای این منظور، تابع کمکی `orthogonalize_attributes` پیاده‌سازی شده است که با استفاده از تجزیه کیو-آر^{۶۵} در کتابخانه `Numpy (np.linalg.qr)`، ماتریس ویژگی‌های اولیه را به یک فضای متعامد انتقال می‌دهد و خروجی آن به عنوان V_A در اختیار مدل قرار می‌گیرد.

۳.۲. معماری شبکه‌های عصبی و پیاده‌سازی با PyTorch

پس از آماده‌سازی داده‌ها، گام بعدی ساخت معماری مدل‌های یادگیری عمیق است. در این پروژه، برای پیاده‌سازی شبکه‌های عصبی از کتابخانه قدرتمند `PyTorch` استفاده شده است. همچنین برای تضمین تکرارپذیری^{۶۶} نتایج آزمایش‌ها و امکان مقایسه علمی و دقیق مدل‌ها، تابع `set_seed` توسعه داده شده است تا تمامی تولیدکننده‌های اعداد تصادفی (در توابع پایه‌ای پایتون، `Numpy` و `PyTorch`) روی یک مقدار ثابت (عدد ۴۲) قفل شوند.

⁶² Preprocessing

⁶³ Binning

⁶⁴ Feature Orthogonalization

⁶⁵ QR Decomposition

⁶⁶ Reproducibility

معماری‌های توسعه‌داده‌شده شامل سه کلاس اصلی هستند که از nn.Module ارث‌بری می‌کنند:

- کلاس SemiAutoencoder: این کلاس وظیفه پیاده‌سازی نیمه‌خودرمزگذار را بر عهده دارد. ساختار آن شامل دو لایه خطی متراکم (nn.Linear) است: یک لایه برای رمزگذار و یک لایه برای رمزگشا. در مرحله انتشار روبه‌جلو^{۶۷}، ورودی‌ها (که در اینجا بردارهای امتیاز هر آیت‌م در طول تمامی کاربران هستند) از لایه رمزگذار عبور کرده و تابع فعال‌ساز سیگموئید روی آن‌ها اعمال می‌شود تا به یک فضای فشرده (با بعد hidden_dim) نگاشت شوند. خروجی این لایه فشرده‌شده، همان ویژگی‌های پنهان اولیه آیت‌م‌ها است که قرار است به‌عنوان نقطه شروع و مقداردهی اولیه برای مدل اصلی استفاده شود.
- کلاس DMF (مدل پایه): این کلاس، پیاده‌سازی مدل فاکتورگیری ماتریس عمیق استاندارد است. در متد مقداردهی اولیه (__init__)، ماتریس ویژگی‌های پنهان آیت‌م‌ها (V) با استفاده از nn.Parameter و توزیع تصادفی نرمال ساخته می‌شود. استفاده از nn.Parameter به PyTorch می‌فهماند که این ماتریس یک پارامتر قابل یادگیری^{۶۸} است و در فرایند پس‌انتشار خطا^{۶۹} باید وزن‌های آن آپدیت شود.
- سپس، لایه‌های پنهان مدل به‌صورت پویا^{۷۰} و با استفاده از ماژول nn.Sequential بر اساس لیست ابعاد ورودی (hidden_layers) ساخته می‌شوند. تمامی لایه‌ها از تابع فعال‌ساز nn.Sigmoid استفاده می‌کنند که دقیقاً مطابق با فرمول‌بندی غیرخطی در مبانی نظری مقاله است. لایه نهایی شبکه، ویژگی‌های استخراج‌شده را به فضایی با ابعاد تعداد کاربران (num_users) نگاشت می‌کند. در نهایت، متد forward خروجی شبکه را ترانهاد (out.T) می‌کند تا ابعاد ماتریس پیش‌بینی‌شده با ماتریس امتیازات اصلی تطابق داشته باشد.
- کلاس FSTD MF (مدل پیشنهادی): از منظر ساختار لایه‌ها و گراف محاسباتی در PyTorch، معماری کلاس FSTD MF شباهت بسیار زیادی به کلاس DMF دارد؛ زیرا تفاوت و نوآوری اصلی مدل FSTD MF نه در تعداد یا نوع لایه‌ها، بلکه در نحوه محاسبه تابع زیان^{۷۱} و اعمال جریمه‌های انتقال زیرفضا است (که در بخش‌های بعدی به تفصیل شرح داده می‌شود). با این حال، در این کلاس نیز پارامتر V به‌صورت یک تنسور^{۷۲} قابل یادگیری تعریف شده و لایه‌های شبکه به‌صورت پویا برای استخراج ویژگی‌های غیرخطی کاربران و آیت‌م‌ها مونتاژ می‌گردند.

۳.۳. فرمول‌بندی تابع زیان و ترفند مقیاس‌بندی ریاضی

یکی از پیچیده‌ترین و حیاتی‌ترین بخش‌های پیاده‌سازی این مقاله، فرمول‌بندی دقیق تابع زیان و برقراری تعادل ریاضی میان اجزای آن است. در تابع `fstdmf_loss_function`، چندین عملیات کلیدی برای محاسبه خطای شبکه و هدایت فرایند بهینه‌سازی انجام می‌شود:

- نرمال‌سازی امتیازات و ماسک‌گذاری^{۷۳}: از آنجا که خروجی لایه نهایی شبکه عصبی در معماری ما از تابع فعال‌ساز سیگموئید عبور می‌کند (که خروجی آن محدود به بازه صفر و یک است)، ماتریس امتیازات واقعی نیز باید دقیقاً به همین بازه نگاشت

⁶⁷ Forward Pass

⁶⁸ Learnable Parameter

⁶⁹ Backpropagation

⁷⁰ Dynamically

⁷¹ Loss Function

⁷² Tensor

⁷³ Masking

شود. این کار با اعمال فرمول $(R - 1.0)/4.0$ روی ماتریس امتیازات انجام شده است. همچنین با استفاده از یک ماتریس ماسک باینری (mask)، تضمین می‌شود که خطای شبکه صرفاً بر اساس درایه‌های مشاهده‌شده (و نه درایه‌های صفر و نامعلوم) محاسبه گردد.

- محاسبه خطای بازسازی (MSE): خطای میانگین مربعات صرفاً برای درایه‌های معتبر محاسبه شده و بر تعداد کل درایه‌های مشاهده‌شده (num_observed) تقسیم می‌شود.
- اعمال جریمه‌های تنظیم‌سازی: برای جلوگیری از بیش‌برازش^{۷۴}، جریمه‌های L_2 بر روی وزن‌های لایه‌های پنهان (W) با ضریب β و بر روی ماتریس ویژگی‌های پنهان آیت‌ها (V) با ضریب α محاسبه و با خطای اصلی جمع می‌شوند.
- جریمه انتقال زیرفضا و بهینه‌سازی محاسباتی: طبق فرمول تئوری مقاله، عبارت جریمه از طریق محاسبه فاصله تصویر ماتریس V روی زیرفضای V_A تعریف می‌شود که در حالت عادی نیازمند محاسبه ماتریس $V_A V_A^T V$ است. اما در اینجا یک نکته ظریف و مهم ریاضی در پیاده‌سازی تابع `fstdmf_loss_function` لحاظ شده است. از آنجا که در مرحله پیش‌پردازش تضمین کردیم ماتریس ویژگی‌های جانبی متعامد جزئی باشد (یعنی $V_A^T V_A = I$)، بر اساس اصول جبر خطی ثابت می‌شود که نرم فروبنیوس عبارت $|V_A V_A^T V|_F^2$ دقیقاً با عبارت ساده‌تر $|V_A^T V|_F^2$ برابر است. به همین دلیل، در کد توسعه‌داده‌شده، مستقیماً ضرب $V_A^T V$ محاسبه شده (`projection = torch.matmul(V_A_tensor.T, model.V)`) و مربع آن با ضریب $\alpha\eta$ به تابع زیان افزوده می‌شود. این ساده‌سازی هوشمندانه، پیچیدگی محاسباتی و زمان اجرای هر دوره آموزشی را کاهش داده و از عملیات‌های ضرب ماتریسی سنگین و غیرضروری جلوگیری کرده است.

در ترجمه مستقیم فرمول‌های تئوری مقاله به کدهای عملیاتی، یک چالش پنهان ریاضی وجود دارد: خطای اصلی (MSE) معمولاً بر تعداد کل داده‌های مشاهده‌شده (مثلاً ده‌ها هزار درایه در یک مجموعه‌داده) تقسیم می‌شود، در حالی که جملات جریمه و انتقال زیرفضا در حالت عادی ممکن است بر تعداد آیت‌ها تقسیم شوند یا به‌صورت جمع کل باقی بمانند. این عدم تقارن مقیاس باعث می‌شود که اثر جریمه زیرفضا در گراف محاسباتی بسیار قوی‌تر از خطای پیش‌بینی عمل کند؛ در نتیجه شبکه به‌جای یادگیری الگوهای امتیازدهی، صرفاً تلاش می‌کند مقدار جریمه را به صفر برساند (پدیده‌ای که باعث ناپایداری شبکه و افزایش خطا با بالا رفتن پارامتر η می‌شود).

برای حل این بحران و جلوگیری از مرگ شبکه، در پیاده‌سازی این پروژه از یک ترفند مقیاس‌بندی یکپارچه استفاده شده است. همان‌طور که در کدهای تابع زیان مشخص است، تمامی جملات (شامل خطای MSE، جریمه‌های L_2 و خطای پروجکشن زیرفضا) بر یک مخرج مشترک ثابت، یعنی `num_observed` تقسیم شده‌اند. این ابتکار ساختاری باعث می‌شود کفه‌های ترازوی ریاضیات در الگوریتم بهینه‌ساز Adam کاملاً متعادل شوند و پارامترهای α ، β و η دقیقاً همان رفتار نزولی، پایدار و قابل‌کنترلی را نشان دهند که در ادعاهای تئوری مقاله مطرح شده است.

⁷⁴ Overfitting

۳.۴. پیش‌آموزش نیمه‌خودرمزگذار و حلقه‌های آموزش شبکه

روند آموزش در این سیستم توصیه‌گر برای مدل پیشنهادی طی دو مرحله متمایز انجام می‌شود: ابتدا استخراج ویژگی‌های اولیه (پیش‌آموزش^{۷۵}) و سپس بهینه‌سازی شبکه اصلی. پیاده‌سازی این مراحل در قالب توابع مجزا، ماژولار بودن کد و امکان اجرای مطالعات فرسایشی را فراهم کرده است.

- تابع `pretrain_semi_autoencoder` برای حل چالش مقداردهی اولیه تصادفی در شبکه‌های DMF طراحی شده است. در این تابع، ماتریس خلوت امتیازات ابتدا نرمال‌سازی و ماسک‌گذاری شده و سپس به یک شبکه `SemiAutoencoder` تغذیه می‌شود. با استفاده از الگوریتم بهینه‌ساز^{۷۶} Adam و یک نرخ یادگیری^{۷۷} مشخص، شبکه سعی می‌کند خطای بازسازی (تفاوت بین ورودی و خروجی رمزگشا) را طی چندین دوره^{۷۸} به حداقل برساند. پس از پایان آموزش این ماژول، خروجی لایه میانی (رمزگذار) با استفاده از متد `detach` از گراف محاسباتی PyTorch جدا می‌شود تا وابستگی گرادیان‌ها^{۷۹} قطع گردد. این خروجی سپس به عنوان یک ماتریس ویژگی غنی‌شده (V_{init}) برای راه‌اندازی مدل اصلی استخراج می‌شود.
- تابع `train_dmf` وظیفه آموزش شبکه فاکتورگیری ماتریس عمیق را بر عهده دارد. در صورتی که مقداردهی اولیه خاصی (مانند خروجی نیمه‌خودرمزگذار) به این تابع پاس داده شود، جایگزین مقادیر تصادفی ماتریس ویژگی آیت‌ها (V) می‌گردد (`model.V.data = V_init.clone()`). در حلقه آموزش، پس از صفر کردن انباشت گرادیان‌ها با دستور `optimizer.zero_grad()`، انتشار روبه‌جلو انجام شده و خروجی شبکه محاسبه می‌گردد. پس از محاسبه خطا (جمع خطای MSE و تنظیم‌سازهای L_2)، با فراخوانی `loss.backward()` و `optimizer.step()`، وزن‌های لایه‌های شبکه و ماتریس ویژگی‌ها به‌روزرسانی می‌شوند.
- تابع `train_fstdmf` ساختاری مشابه مدل پایه دارد، اما تفاوت کلیدی آن در دریافت ماتریس ویژگی‌های جانبی (V_A) و استفاده از تابع زیان سفارشی است. در این حلقه، تابع `fstdmf_loss_function` (که پیش‌تر ساختار مقیاس‌یافته آن تشریح شد) فراخوانی می‌گردد تا علاوه بر خطای پیش‌بینی، فاصله ویژگی‌های پنهان مدل تا تصویر آن‌ها روی زیرفضای ویژگی‌های جانبی نیز جریمه شود. این تابع به مدل اجازه می‌دهد تا در هر دوره، همزمان با کاهش خطای پیش‌بینی، ساختار هندسی ویژگی‌های خود را با اطلاعات جانبی هم‌راستا کند.

در تمامی این توابع، از متدهای استاندارد `model.train()` و `model.eval()` در فریم‌ورک PyTorch استفاده شده است. این متدها تضمین می‌کنند که شبکه به‌درستی بین فازهای آموزش و ارزیابی تغییر وضعیت داده و در زمان تست مدل، از محاسبات اضافی گرادیان جلوگیری شود.

⁷⁵ Pre-training

⁷⁶ Optimizer

⁷⁷ Learning Rate

⁷⁸ Epoch

⁷⁹ Gradients

۳.۵. تقسیم‌بندی داده‌ها و مکانیزم ارزیابی مدل

برای ارزیابی منصفانه و علمی مدل‌های پیاده‌سازی‌شده، ضروری است که ماتریس اصلی به دو بخش آموزش و آزمون تقسیم شود تا از توانایی تعمیم‌پذیری شبکه اطمینان حاصل گردد. این وظیفه در کد پروژه توسط تابع `create_train_test_split` انجام می‌پذیرد.

روند کار به این صورت است که ابتدا تمامی درایه‌های غیرصفر در ماتریس (که نشان‌دهنده امتیازات ثبت‌شده^{۸۰} توسط کاربران هستند) با استفاده از توابع Numpy استخراج می‌شوند. سپس با استفاده از توابع تصادفی (که پیش‌تر با متد `set_seed` روی عدد ثابت قفل شده‌اند)، ترتیب این درایه‌ها کاملاً بر هم زده می‌شود تا توزیع داده‌ها یکنواخت باشد. بر اساس نسبت آموزش تعیین‌شده در صورت‌سوال (`train_ratio`) که در آزمایش‌های این پروژه برابر با 0.7 ، 0.5 و 0.3 تنظیم شده است، داده‌ها برش می‌خورند. مقادیر مربوط به فاز آموزش در یک ماتریس جدید به نام `R_train` جایگذاری می‌شوند (که مدل تنها حق دارد این ماتریس خلوت‌تر را برای یادگیری ببیند) و مختصات مقادیر آزمون نیز در قالب یک لیست (`test_indices`) برای مراحل بعد ذخیره می‌گردند.

پس از اتمام فرایند آموزش شبکه‌ها، تابع `evaluate_model` برای سنجش عملکرد و استخراج میزان خطای نهایی فراخوانی می‌شود. در این تابع دو اقدام کلیدی صورت گرفته است:

- توقف محاسبات گرادیان: ابتدا شبکه با دستور `model.eval()` در فاز ارزیابی قرار می‌گیرد و با استفاده از بلاک `torch.no_grad()`، تمامی محاسبات مربوط به مشتق‌گیری و انباشت گرادیان‌ها متوقف می‌شود. این کار باعث می‌شود تا سرعت پردازش در فاز تست به شدت افزایش یافته و حافظه سیستم بی‌دلیل اشغال نشود.
- مقیاس‌بندی مجدد^{۸۱} خروجی‌ها: از آنجا که مدل بر اساس داده‌های نرمال‌سازی‌شده آموزش دیده است و خروجی لایه آخر آن (به دلیل وجود تابع سیگموئید) مقداری بین صفر و یک دارد، این مقادیر باید پیش از محاسبه خطا، مجدداً به فضای امتیازات واقعی (بازه ۱ تا ۵) بازگردانده شوند. این نگاشت معکوس در کد با فرمول $(predictions * 4.0) + 1.0$ پیاده‌سازی شده است.

در نهایت، با پیمایش حلقه روی لیست مختصات آزمون، اختلاف میان امتیازات پیش‌بینی‌شده و امتیازات واقعی استخراج شده و دو معیار ارزیابی پروژه، یعنی خطای مطلق میانگین (MAE) و ریشه میانگین مربعات خطا (RMSE) محاسبه و به کاربر برگردانده می‌شوند.

۳.۶. معماری اجرای سناریوها و تولید خروجی‌ها

برای پیوند دادن تمامی ماژول‌های توسعه‌داده‌شده (از پردازش داده تا حلقه‌های آموزش) و شبیه‌سازی دقیق آزمایش‌های مقاله، مجموعه‌ای از توابع پوشاننده^{۸۲} طراحی شده‌اند که نقش ارکستراتور (مدیر اجرایی) را ایفا می‌کنند. توابعی نظیر `run_movielens100k_experiment` و `run_movielens1m_experiment` تمامی مراحل را در یک جریان کاری یکپارچه مدیریت می‌کنند. در این توابع، ابتدا ابرپارامترهای^{۸۳} شبکه (نظیر نرخ یادگیری 0.0123 ، جستجوی شبکه‌ای برای یافتن بهترین

⁸⁰ Observed Ratings

⁸¹ Rescaling

⁸² Wrapper Functions

⁸³ Hyperparameters

ضرایب تنظیم‌سازی α و β در بازه $\{0.10, 0.15\}$ و پارامتر اطمینان $\eta=1.0$ مطابق با تنظیمات بهینه مقاله تعریف می‌شوند. سپس در یک حلقه تکرار، مدل‌های پایه (DMF) و پیشنهادی (FSTDMF) روی نسبت‌های مختلف داده آموزشی (۷۰، ۵۰ و ۳۰ درصد) آموزش دیده و خطای آن‌ها ثبت می‌گردد.

به‌منظور بررسی عمیق‌تر رفتار مدل و پاسخ به اهداف پروژه درس، سه تابع دیگر نیز پیاده‌سازی شده است که سناریوهای تحلیلی را مدیریت می‌کنند:

- تحلیل حساسیت ابعاد: در تابع `run_dimension_sensitivity_analysis`، شبکه با ابعاد ویژگی پنهان متفاوت (مقادیر ۱۰۰، ۳۰۰ و ۵۰۰) مقداردهی شده و خطای آن در هر سه حالت نسبت آموزش محاسبه می‌گردد تا میزان پایداری مدل در برابر تغییر ابعاد سنجیده شود.
- تحلیل حساسیت عمق شبکه: تابع `run_layer_sensitivity_analysis` عملکرد معماری‌های تک‌لایه [100]، دو‌لایه [100, 100] و سه‌لایه [100, 100, 100] را مقایسه می‌کند تا بهینه‌ترین ساختار غیرخطی شبکه شناسایی گردد.
- مطالعه فرسایشی: تابع `run_ablation_study` با فعال و غیرفعال کردن هوشمندانه ورودی‌ها، چهار سناریوی مستقل را اجرا می‌کند: مدل پایه (DMF)، مدل پایه فقط با مقداردهی اولیه (DMF+SA)، مدل پایه فقط با انتقال ویژگی تصادفی (DMF+FST) و مدل کامل (FSTDMF). این جداسازی به ما اجازه می‌دهد سهم دقیق هر ماژول را در کاهش خطا اندازه‌گیری کنیم.

در نهایت، بخش تولید خروجی‌ها و مصورسازی^{۸۴} نتایج پیاده‌سازی شده است. تابع `compare_with_paper` یک ماژول اعتبارسنجی است که خروجی‌های مدل پیاده‌سازی‌شده را مستقیماً با مقادیر جداول ۳ و ۴ مقاله اصلی مقایسه کرده و درصد اختلاف (Δ/Δ) را در خروجی چاپ می‌کند تا صحت عملکرد کد تأیید شود. در گام آخر، با استفاده از کتابخانه `Matplotlib`، کدهای لازم برای رسم سه گراف اصلی توسعه داده شده است. این گراف‌ها، نمودارهای مربوط به تحلیل ابعاد، مقایسه عمق لایه‌ها و نمودار میله‌ای مطالعه فرسایشی را تولید کرده و در قالب فایل‌های تصویری با رزولوشن بالا ذخیره می‌کنند تا مستقیماً در بخش نتایج گزارش (فصل چهارم) مورد تحلیل قرار گیرند.

فصل چهارم – نتایج آزمایش‌ها، ارزیابی و تحلیل عملکرد مدل

۴.۱. مقدمه و تنظیمات اجرایی ارزیابی

پس از پیاده‌سازی کامل ساختار ریاضی و معماری شبکه‌های عصبی مدل پیشنهادی (FSTDMF) و مدل پایه (DMF)، برای ارزیابی تجربی و اعتبارسنجی سیستم، آزمایش‌های جامع روی دو مجموعه داده استاندارد دنیای واقعی یعنی MovieLens-100K و MovieLens-1M انجام گرفته است. در تمامی این آزمایش‌ها، برای پوشش‌دهی کامل چالش پراکندگی داده‌ها، ماتریس امتیازات کاربران-آیتم‌ها با سه نسبت مختلف برای مجموعه آموزش (شامل ۷۰٪، ۵۰٪ و ۳۰٪ از کل داده‌های معتبر) تفکیک شده و مابقی داده‌ها برای فاز آزمون در نظر گرفته شده‌اند.

همچنین، پیرو جستجوی بهینه‌سازی ابرپارامترها، ضریب تنظیم‌سازی (α و β) در بازه $\{0.10, 0.15\}$ ارزیابی شده و بهترین نتیجه برای هر سناریو ثبت گردیده است. در ادامه، نتایج کمی حاصل از اجرای کدهای پروژه و مقایسه آن‌ها با مقادیر مرجع ارائه شده در مقاله اصلی مورد تحلیل و واکاوی قرار می‌گیرد.

۴.۲. ارزیابی عملکرد روی مجموعه داده MovieLens-100K

مجموعه داده MovieLens-100K به عنوان نخستین محک استاندارد، شامل ۱۰۰,۰۰۰ امتیازدهی است. در این سناریو، مدل پایه DMF و مدل پیشنهادی FSTDMF با ابعاد ویژگی پنهان ۱۰۰ و ۵۰ دوره روی داده‌ها آموزش دیده‌اند. نتایج کمی به دست آمده از اجرای کد برای این مجموعه داده در مقایسه با مقادیر گزارش شده در جدول ۳ مقاله اصلی تنظیم شده است.

مدل	نسبت آموزش	MAE به دست آمده	MAE مقاله	انحراف درصد (Δ)	RMSE به دست آمده	RMSE مقاله	انحراف درصد (Δ)
DMF	0.7	0.738	0.729	+1.2%	0.943	0.926	+1.8%
DMF	0.5	0.754	0.744	+1.3%	0.962	0.944	+1.9%
DMF	0.3	0.781	0.767	+1.8%	0.997	0.972	+2.5%
FSTDMF	0.7	0.719	0.701	+2.6%	0.923	0.893	+3.3%
FSTDMF	0.5	0.731	0.713	+2.5%	0.933	0.909	+2.6%
FSTDMF	0.3	0.754	0.744	+1.3%	0.961	0.945	+1.7%

جدول ۱: مقایسه خطای پیش‌بینی میان مدل DMF و FSTDMF روی مجموعه داده MovieLens-100K با مقادیر مقاله اصلی

همان‌طور که در جدول ۱ مشاهده می‌شود، با کاهش نسبت داده‌های آموزشی از ۷۰٪ به ۳۰٪، میزان خطای تمامی مدل‌ها (هم در معیار MAE و هم در معیار RMSE) به‌طور طبیعی افزایش می‌یابد؛ چرا که خلوت‌تر شدن ماتریس و کاهش داده‌های آموزشی، کار پیش‌بینی را دشوارتر می‌کند. با این حال، مقایسه میان دو مدل نشان می‌دهد که مدل پیشنهادی FSTDMF در تمامی نسبت‌ها عملکرد به مراتب بهتری نسبت به مدل پایه DMF ثبت کرده است.

به عنوان مثال، در نسبت آموزش ۷۰٪، مدل FSTDMF به خطای MAE معادل ۰/۷۱۹ دست یافته است، در حالی که مدل پایه خطای ۰/۷۳۸ را ثبت کرده است. این برتری ثابت می‌کند که مکانیزم انتقال زیرفضای ویژگی توانسته است اطلاعات جانبی صفات فیلم‌ها (سال تولید و ژانر) را به‌شکلی اثربخش به مدل تزریق کرده و کاستی‌های ناشی از ساختار خطی و ساده را جبران کند. همچنین، انحرافات مثبت اندک (Δ) میان کدهای اجرا شده و مقادیر مقاله اصلی (در حدود ۱ تا ۳ درصد) کاملاً در بازه استاندارد

خطای بازتولید^{۸۵} قرار دارد که ناشی از تفاوت در سخت‌افزار، کتابخانه‌های بهینه‌سازی (استفاده از Adam بهینه‌ساز در پیاده‌سازی ما در برابر الگوریتم iRprop+ در مقاله اصلی) و واریانس تصادفی اولیه شبکه‌های عصبی است.

۴.۳. ارزیابی عملکرد روی مجموعه‌داده MovieLens-1M

برای سنجش پایداری و مقیاس‌پذیری^{۸۶} معماری‌های پیاده‌سازی شده در مواجهه با داده‌های حجیم‌تر، آزمایش‌ها بر روی مجموعه‌داده MovieLens-1M تکرار گردید. این مجموعه‌داده با دارا بودن بیش از یک میلیون امتیاز ثبت‌شده، بستر مناسب‌تری برای ارزیابی قابلیت‌های یادگیری شبکه‌های عصبی عمیق فراهم می‌کند.

همانند سناریوی قبل، مدل پایه (DMF) و مدل پیشنهادی (FSTDMF) با ابعاد پنهان ۱۰۰، نرخ یادگیری ۰/۰۱۲۳ و روی سه نسبت آموزشی ۷۰، ۵۰ و ۳۰ درصد آموزش دیدند. نتایج ارزیابی مدل‌های پیاده‌سازی شده و مقایسه آن‌ها با مقادیر ارائه‌شده در مقاله (جدول ۴ مقاله اصلی) در جدول ۲ گردآوری شده است.

مدل	نسبت آموزش	MAE به‌دست‌آمده	MAE مقاله	انحراف درصد (Δ)	RMSE به‌دست‌آمده	RMSE مقاله	انحراف درصد (Δ)
DMF	0.7	0.717	0.693	+3.4%	0.913	0.854	+6.9%
DMF	0.5	0.719	0.700	+2.7%	0.916	0.871	+5.2%
DMF	0.3	0.728	0.720	+1.1%	0.928	0.914	+1.5%
FSTDMF	0.7	0.703	0.667	+5.4%	0.894	0.850	+5.1%
FSTDMF	0.5	0.706	0.678	+4.2%	0.899	0.863	+4.2%
FSTDMF	0.3	0.716	0.696	+2.9%	0.914	0.885	+3.3%

جدول ۲: مقایسه خطای پیش‌بینی میان مدل DMF و FSTDMF روی مجموعه‌داده MovieLens-1M با مقادیر مقاله اصلی

در تمامی نسبت‌های آموزشی، مدل FSTDMF خطای کمتری نسبت به مدل DMF دارد. به‌عنوان نمونه در نسبت آموزش ۷۰ درصد، خطای MAE از ۰/۷۱۷ (در مدل پایه) به ۰/۷۰۳ کاهش یافته است. این امر ثابت می‌کند که استراتژی انتقال زیرفضای ویژگی و استفاده از اطلاعات جانبی (ژانر و سال تولید)، حتی در مجموعه‌داده‌های بزرگ‌تر نیز کاملاً اثربخش عمل کرده و مشکل پراکندگی را تسکین می‌دهد.

با مقایسه ارقام جدول ۱ و جدول ۲ به‌وضوح مشخص می‌شود که خطای مدل‌ها در مجموعه‌داده یک میلیونی به‌طور میانگین کمتر از مجموعه‌داده صد هزاری است. به‌عنوان مثال، خطای DMF در حالت ۳۰ درصد آموزش روی مجموعه‌داده کوچک برابر ۰/۷۸۱ بود، اما روی مجموعه‌داده بزرگ به ۰/۷۲۸ کاهش یافته است. این کاهش خطا ذات شبکه‌های عصبی عمیق را تأیید می‌کند که اصطلاحاً تشنه داده (Data-hungry) هستند و با افزایش حجم نمونه‌های آموزشی، توانایی آن‌ها در استخراج الگوهای غیرخطی بهینه‌تر می‌شود.

همان‌طور که در ستون‌های انحراف درصد مشاهده می‌شود، اختلاف کدهای اجرا شده با مقادیر ایده‌آل مقاله در این مجموعه‌داده بزرگ، بین ۱ تا ۶/۹ درصد است. دلیل این امر، تفاوت در رویکرد بهینه‌سازی است. مقاله اصلی برای ماتریس‌های مقیاس‌بزرگ^{۸۷} از الگوریتم تخصصی iRprop+ بهره برده است که برای فضاهای بسیار خلوت عملکرد هندسی متفاوتی دارد، در حالی که در این

^{۸۵} Reproduction Variance

^{۸۶} Scalability


^{۸۷} Large-scale Matrices

پیاده‌سازی از بهینه‌ساز استاندارد Adam در بستر PyTorch استفاده شده است. با این وجود، از آنجا که هدف اصلی مقاله اثبات برتری مدل FSTD MF نسبت به DMF بوده است، روند نزولی خطاها در کدهای پروژه کاملاً این فرضیه را تأیید و اثبات می‌کند.

۴.۴. تحلیل حساسیت نسبت به ابعاد ویژگی پنهان

یکی از پارامترهای تأثیرگذار بر عملکرد شبکه‌های عصبی در سیستم‌های توصیه‌گر، اندازه یا بعد ویژگی‌های پنهان (r) است. این پارامتر تعیین می‌کند که مدل چه میزان ظرفیت برای ذخیره‌سازی و بازنمایی ویژگی‌های پیچیده و الگوهای غیرخطی رفتار کاربران و آیتم‌ها دارد. برای بررسی حساسیت مدل نسبت به تغییرات این پارامتر، عملکرد دو مدل DMF و FSTD MF روی مجموعه‌داده MovieLens-1M تحت سه بعد مختلف ($r \in \{100, 300, 500\}$) و در سه نسبت آموزشی مجزا ارزیابی گردید.

نتایج این تحلیل حساسیت در کدهای پیاده‌سازی شده استخراج و در قالب نمودارهای بصری در شکل ۱ به تصویر کشیده شده است.



شکل ۱: نمودار خطای MAE بر حسب ابعاد ویژگی پنهان (r) در مدل‌های DMF و FSTD MF با نسبت‌های آموزش ۰/۷، ۰/۵ و ۰/۳ روی مجموعه‌داده MovieLens-1M

با بررسی دقیق روند نمودارهای رسم شده و مقایسه آن‌ها با مقادیر خروجی کد، نتایج زیر حاصل می‌شود:

- در هر سه حالت از نسبت‌های آموزشی (۷۰، ۵۰ و ۳۰ درصد)، منحنی مربوط به مدل FSTD MF (نمودار با نشانگرهای مربع) به‌طور پیوسته پایین‌تر از منحنی مدل DMF (نمودار با نشانگرهای دایره) قرار گرفته است. به‌عنوان مثال، در نسبت آموزش ۳۰ درصد و با بعد $r = 500$ ، خطای MAE در مدل DMF برابر ۰/۷۵۰ است، درحالی‌که این مقدار در مدل FSTD MF برابر ۰/۷۲۹ ثبت شده است. این شکاف پایدار نشان می‌دهد که مکانیزم انتقال زیرفضای ویژگی، مستقل از حجم ماتریس ویژگی‌ها، توانایی خود را در کاهش خطا حفظ می‌کند.
- یک رفتار بسیار مهم که در کدهای پیاده‌سازی شده و نمودارهای شکل ۱ به‌وضوح مشاهده می‌شود، روند صعودی خطا (افت عملکرد) با افزایش بعد ویژگی پنهان از ۱۰۰ به ۵۰۰ است. در مدل FSTD MF با نسبت آموزش ۰/۷، کمترین خطا (MAE=0.703) در بعد $r = 100$ و $r = 300$ به دست آمده است، اما با افزایش بعد به $r = 500$ ، خطا به ۰/۷۲۰ افزایش می‌یابد.

این پدیده که با مشاهدات تئوری مقاله مطابقت دارد، به‌دلیل بیش‌برازش رخ می‌دهد. هنگامی که بعد ویژگی پنهان بسیار بزرگ در نظر گرفته شود ($r = 500$)، شبکه عصبی پارامترهای بسیار زیادی برای یادگیری در اختیار خواهد داشت. در شرایطی که ماتریس

امتیازات (به‌ویژه در مجموعه‌داده‌های خلوت) اطلاعات کافی برای تنظیم دقیق این حجم از پارامترها را ندارد، مدل شروع به حفظ کردن نویزهای موجود در داده‌های آموزشی می‌کند و در نتیجه، قدرت تعمیم‌پذیری^{۸۸} آن روی داده‌های آزمون کاهش می‌یابد.

با تطبیق روند به‌دست‌آمده در پیاده‌سازی حاضر با نمودارهای گزارش‌شده در مقاله اصلی، تطابق معناداری در برتری مطلق مدل FSTD MF بر DMF در تمامی ابعاد مشاهده می‌شود. در نمودارهای مقاله نیز منحنی مدل پیشنهادی (FSTD MF) همواره پایین‌تر از مدل پایه (DMF) قرار دارد. با این حال، یک تفاوت ظریف در میزان حساسیت به بعد پنهان وجود دارد؛ در نتایج مقاله، خطای FSTD MF با افزایش ابعاد از ۱۰۰ تا ۶۰۰ تغییرات اندکی داشته و تقریباً افقی و پایدار باقی می‌ماند، درحالی‌که در پیاده‌سازی حاضر، افزایش بعد به ۵۰۰ با شیب تندتری به افزایش خطا (بیش‌برازش) منجر شده است. این تفاوت در نرخ بیش‌برازش در ابعاد بالا، ناشی از تفاوت در الگوریتم بهینه‌ساز (Adam در کدهای ما در برابر الگوریتم irprop+ در مقاله) است؛ با این وجود، در اصل اثبات کارایی مدل پیشنهادی و برتری آن در ابعاد برابر، خللی ایجاد نمی‌کند.

بر اساس این مشاهدات تجربی، تنظیم بعد ویژگی پنهان روی $r = 100$ ، نقطه تعادل ایده‌آل میان ظرفیت بازنمایی شبکه و جلوگیری از بیش‌برازش را فراهم می‌کند. به همین دلیل، در سایر ارزیابی‌های انجام‌شده در این پروژه، مقدار $r = 100$ به‌عنوان پارامتر پیش‌فرض شبکه‌ها تثبیت شده است.

۴.۵. تحلیل حساسیت نسبت به تعداد لایه‌های پنهان^{۸۹}

در شبکه‌های عصبی عمیق، تعداد لایه‌های پنهان مستقیماً بر میزان توانایی مدل در استخراج تعاملات غیرخطی و پیچیده تأثیر می‌گذارد. با این حال، افزایش بی‌رویه عمق شبکه لزوماً به معنای بهبود عملکرد نیست و می‌تواند به مشکلاتی نظیر محوشدگی گرادینان^{۹۰} یا افزایش بیش‌برازش منجر شود. برای بررسی این ویژگی در سیستم توصیه‌گر، مدل پیشنهادی FSTD MF با سه معماری متفاوت شامل تک‌لایه (با ۱۰۰ نورون)، دو‌لایه (هر کدام ۱۰۰ نورون) و سه‌لایه (هر کدام ۱۰۰ نورون) بر روی مجموعه‌داده MovieLens-100K آموزش دید و ارزیابی شد.

به‌منظور مقایسه دقیق دستاوردهای پیاده‌سازی عملی با یافته‌های تئوری، نتایج خطای MAE به‌دست‌آمده از اجرای کدها در کنار مقادیر صریح گزارش‌شده در جدول ۸ مقاله اصلی، در جدول ۳ گردآوری شده است.

معماری مدل	نسبت آموزش	MAE به‌دست‌آمده	MAE مقاله	RMSE به‌دست‌آمده	RMSE مقاله
تک‌لایه	0.7	0.719	0.718	0.923	0.910
دو‌لایه	0.7	0.738	0.701	0.940	0.893
سه‌لایه	0.7	0.738	0.714	0.941	0.912
تک‌لایه	0.5	0.731	0.734	0.933	0.931
دو‌لایه	0.5	0.744	0.713	0.946	0.909
سه‌لایه	0.5	0.744	0.722	0.951	0.923

^{۸۸} Generalization


^{۸۹} Hidden Layers

^{۹۰} Vanishing Gradient

تک لایه	0.3	0.754	0.773	0.961	0.977
دو لایه	0.3	0.761	0.744	0.967	0.945
سه لایه	0.3	0.766	0.746	0.980	0.951

جدول ۳: مقایسه خطای MAE و RMSE در لایه‌های مختلف میان پیاده‌سازی عملی و جدول ۸ مقاله (MovieLens-100K)

روند تغییرات خطای پیش‌بینی (MAE) نسبت به افزایش تعداد لایه‌ها در شکل ۲ به تصویر کشیده شده است.



شکل ۲: روند تغییرات خطای MAE در مدل پیشنهادی FSTDMF به‌ازای افزایش تعداد لایه‌های پنهان در نسبت‌های مختلف آموزش (مجموعه داده MovieLens-100K)


با واکاوی داده‌های خروجی و مقایسه آن با مقادیر مقاله اصلی، حقایق زیر نمایان می‌شود:

- در تمامی نسبت‌های آموزشی (۷۰، ۵۰ و ۳۰ درصد)، کمترین میزان خطای MAE و RMSE مربوط به معماری تک‌لایه (1-layer) است. به‌عنوان نمونه، در نسبت آموزش ۷۰ درصد، خطای مدل تک‌لایه برابر ۰/۷۱۹ بوده است، درحالی‌که با افزودن لایه دوم، خطا به ۰/۷۳۸ افزایش یافته و در معماری سه‌لایه روی همین عدد ثابت مانده است. این در حالی است که بر اساس یافته‌های مقاله اصلی (جدول بالا)، معماری دو‌لایه بهترین عملکرد (خطای ۰/۷۰۱ در نسبت ۷۰٪) را به ثبت رسانده است و می‌توان گفت میان نتایج ما و ادعای مقاله یک تناقض وجود دارد.
- این افزایش خطا با عمیق‌تر شدن شبکه، علاوه‌بر محدودیت دوره‌های آموزشی، یک ریشه ساختاری و بسیار مهم در معماری شبکه‌های عصبی دارد که به آن محوشدگی گرادیان می‌گویند. در پیاده‌سازی این معماری، مطابق با فرمول‌بندی پایه مقاله، از تابع فعال‌ساز سیگموئید در تمامی لایه‌های پنهان استفاده شده است. از آنجا که مشتق تابع سیگموئید همواره مقداری کوچکتر از ۰/۲۵ دارد، با ضرب شدن پیاپی این مشتقات در الگوریتم پس‌انتشار خطا برای لایه‌های عمیق‌تر (دو لایه و سه لایه)، مقدار گرادیان به‌سرعت به سمت صفر میل می‌کند. این پدیده باعث می‌شود لایه‌های ابتدایی شبکه عملاً به‌روزرسانی نشده و چیزی یاد نگیرند؛ در نتیجه خطا با افزایش عمق شبکه به‌طور یکنواخت بدتر می‌شود. بنابراین، اگرچه محدودیت ۵۰ دوره برای هم‌گرایی شبکه‌های عمیق‌تر بی‌تأثیر نیست، اما مقصر و گلوگاه اصلی در افت عملکرد مدل‌های چندلایه، پشته‌سازی توابع سیگموئید است که توانایی شبکه برای استفاده از ظرفیت یادگیری لایه‌های عمیق را فلج می‌کند.
- این آزمایش تجربی نشان می‌دهد که برای مجموعه داده‌های خلوت و کوچک (نظیر MovieLens-100K)، یک لایه پنهان با ۱۰۰ گره، ظرفیت و تعادل ایده‌آلی برای تقریب زدن تابع غیرخطی سلیقه کاربران دارد. به همین دلیل، در مطالعات فرسایشی و سایر آزمایش‌های پایه‌ای، از معماری تک‌لایه برای مقایسه مدل‌ها استفاده شده است تا از خطاهای ناشی از پیچیدگی مازاد و عدم هم‌گرایی کامل در شبکه‌های عمیق‌تر جلوگیری شود.

۴.۶. مطالعه فرسایشی (حذف اجزا) و تحلیل اثربخشی اجزای مدل

برای ارزیابی دقیق و مجزای هر یک از نوآوری‌های اضافه‌شده به معماری فاکتورگیری ماتریس عمیق، یک مطالعه فرسایشی طراحی و اجرا شد. هدف از این مطالعه، پاسخ به این پرسش است که هر یک از دو مکانیزم نیمه‌خودرمزگذار (SA) و انتقال زیرفضای ویژگی (FST) به‌تنهایی چه سهمی در کاهش خطای پیش‌بینی دارند و ترکیب آن‌ها چه هم‌افزایی و ارزش افزوده‌ای ایجاد می‌کند.

به این منظور، چهار سناریوی مستقل (شامل مدل پایه DMF، مدل مجهز به نیمه‌خودرمزگذار DMF+SA، مدل مجهز به جریحه انتقال ویژگی DMF+FST و در نهایت مدل کامل FSTD MF) بر روی مجموعه‌داده MovieLens-100K ارزیابی شدند. نتایج مقایسه‌ای خطای MAE برای این چهار معماری در شکل ۳ به‌صورت نمودار میله‌ای به تصویر کشیده شده است.



شکل ۳: نمودار میله‌ای مقایسه خطای MAE در مطالعه فرسایشی میان چهار معماری مختلف شبکه روی مجموعه‌داده MovieLens-100K

- با بررسی دقیق ارتفاع میله‌ها در نمودار و همچنین ارقام ثبت‌شده در خروجی کد، سه نتیجه‌گیری حیاتی و علمی حاصل می‌شود:
- در تمامی نسبت‌های آموزشی (۷۰، ۵۰ و ۳۰ درصد)، هر دو مدل ارتقا یافته (یعنی DMF+SA و DMF+FST) توانسته‌اند خطای کمتری نسبت به مدل کلاسیک DMF ثبت کنند. به‌عنوان مثال، در نسبت آموزش بسیار خلوت ۳۰ درصد، خطای مدل پایه ۰/۷۸۱ است؛ اما با اضافه شدن ماژول FST این خطا به ۰/۷۷۴ و با اضافه شدن ماژول SA به ۰/۷۶۳ کاهش یافته است. این امر ثابت می‌کند که هم مقداردهی اولیه هوشمند و هم انتقال اطلاعات جانبی، استراتژی‌های موفقی برای مقابله با پراکندگی داده‌ها هستند.
 - با مقایسه دو میله میانی در شکل ۳ متوجه می‌شویم که در مجموعه‌داده نسبتاً کوچکی مانند MovieLens-100K، مدل DMF+SA تأثیر بسیار قدرتمندتری در کاهش خطا نسبت به DMF+FST داشته است. این مشاهده تجربی نشان می‌دهد که در مجموعه‌داده‌های کوچک، پیدا کردن یک نقطه شروع مناسب برای شبکه‌های عصبی عمیق (از طریق پیش‌آموزش نیمه‌خودرمزگذار) اثر فوری و عمیقی بر مسیر نزول گرادیان^{۹۱} دارد و از گیر افتادن شبکه در کمینه‌های محلی نامطلوب جلوگیری می‌کند.
 - برترین عملکرد در تمامی شرایط، متعلق به معماری یکپارچه FSTD MF (میله چهارم) است. اوج این هم‌افزایی^{۹۲} را می‌توان در سخت‌ترین شرایط آزمایش (نسبت آموزش ۳۰ درصد) مشاهده کرد. در این حالت، مدل ترکیبی به خطای MAE معادل ۰/۷۵۴ دست یافته است که به‌وضوح از عملکرد انفرادی DMF+SA (با خطای ۰/۷۶۳) و DMF+FST

^{۹۱} Gradient Descent Path

^{۹۲} Synergy

(با خطای ۰/۷۷۴) بهتر است. این دستاورد، ادعای نهایی مقاله را اثبات می‌کند: مقداردهی اولیه هوشمند و انتقال ویژگی‌های جانبی، دو بازوی مکمل یکدیگر هستند و ترکیب آن‌ها در یک تابع هدف واحد، به بالاترین سطح از دقت در سیستم‌های توصیه‌گر منجر می‌شود.

فصل پنجم - نتیجه‌گیری و جمع‌بندی نهایی

۵.۱. مرور کلی مسئله و نوآوری‌های معماری

هدف نهایی این پژوهش، مقابله با یکی از دیرینه‌ترین چالش‌های سیستم‌های توصیه‌گر، یعنی معضل پراکندگی داده‌ها در ماتریس تعاملات کاربر-آیتم بود. درحالی‌که روش‌های فاکتورگیری ماتریس سنتی و حتی معماری‌های اولیه یادگیری عمیق (نظیر مدل‌های پایه DMF) گام‌های مهمی در استخراج الگوهای پنهان برداشته‌اند، اما محدودیت‌های آن‌ها در مواجهه با داده‌های خلوت و عدم استفاده بهینه از اطلاعات جانبی، اثربخشی آن‌ها را در محیط‌های واقعی کاهش می‌داد.

معماری پیشنهادی FSTD MF که در این گزارش به‌طور جامع بررسی و پیاده‌سازی شد، توانست با تلفیق هوشمندانه دو راهکار متمایز، بر این موانع غلبه کند:

- ابتدا، جایگزینی رویکردهای ساده تصادفی (مانند توزیع گاوسی) با یک شبکه نیمه‌خودرمزگذار برای مقداردهی اولیه ماتریس ویژگی‌های پنهان. این ابتکار به مدل اجازه داد تا پیش از شروع بهینه‌سازی شبکه اصلی، یک درک اولیه و فشرده از ساختار داده‌ها به‌دست آورد.
- دوم، معرفی یک مکانیزم ریاضیاتی قدرتمند مبتنی بر فاصله تصویر بر روی زیرفضا برای انتقال دانش. این معماری نشان داد که چگونه می‌توان ویژگی‌های جانبی (مانند سال تولید و ژانر در مجموعه‌داده MovieLens) را بدون درگیر شدن با پیچیدگی‌های ساختاری، مستقیماً به جریان یادگیری وظیفه هدف (پیش‌بینی امتیاز) تزریق کرد تا فضای خالی ماتریس امتیازات جبران شود.

۵.۲. دستاوردهای پیاده‌سازی عملی و چالش‌های فنی

ارزش علمی این پروژه صرفاً به بررسی تئوری محدود نشد، بلکه پیاده‌سازی عملی این چارچوب پیچیده با استفاده از کتابخانه PyTorch، چالش‌ها و ظرایف مهندسی متعددی را به همراه داشت که با موفقیت برطرف گردیدند. توسعه صفر تا صد این معماری، از پیش‌پردازش دقیق داده‌ها و کدگذاری ویژگی‌ها تا مونتاژ پویای گراف محاسباتی^{۹۳} شبکه‌های عصبی عمیق، تسلط بر ابزارهای نوین یادگیری ماشین را به اثبات رساند.

یکی از مهم‌ترین دستاوردهای فنی در این پروژه، درک و مهار پدیده ناپایداری گرادیان‌ها در تابع زیان بود. ترجمه مستقیم فرمول‌های نظری به کدهای عملیاتی نشان داد که عدم تقارن در مقیاس محاسبه خطای میانگین مربعات (MSE) نسبت به جریمه‌های تنظیم‌سازی و فاصله زیرفضا، می‌تواند به سرعت منجر به توقف یادگیری و مرگ شبکه شود.

اعمال ترفند مقیاس‌بندی یکپارچه (تقسیم تمامی جملات تابع زیان بر تعداد کل درایه‌های مشاهده‌شده) یک مداخله کلیدی بود که پایداری ریاضیات بهینه‌ساز را در طول ده‌ها دوره تضمین کرد. همین دقت در پیاده‌سازی باعث شد تا کدهای توسعه‌داده‌شده بتوانند در رقابت با معماری مقاله مرجع، به انحراف‌های حداقلی و قابل قبولی (در بازه خطای بازتولید استاندارد) دست یابند.

⁹³ Computational Graph

در مقاله مرجع، برای بهینه‌سازی تابع هدف غیرمحدب مدل از الگوریتم BFGS برای مجموعه داده‌های کوچک و از الگوریتم تخصصی iRprop+ (انتشار پس‌رو مقاوم بهبودیافته) برای مجموعه داده‌های مقیاس‌بزرگ نظیر MovieLens-1M استفاده شده است. با این وجود، در پیاده‌سازی عملی این پروژه، الگوریتم تطبیقی Adam با نرخ یادگیری ثابت، جایگزین این روش‌ها گردید. دلیل اصلی این تصمیم مهندسی، سازگاری و یکپارچگی بومی الگوریتم Adam با فریم‌ورک PyTorch، کارایی اثبات‌شده آن در آموزش شبکه‌های عصبی عمیق و مدیریت بسیار بهینه‌تر حافظه نسبت به الگوریتم‌های Full-batch (نظیر BFGS) بوده است. پیاده‌سازی سفارشی الگوریتم iRprop+ در پایتون برای چنین گراف محاسباتی پیچیده‌ای، می‌توانست به ناپایداری‌های پیش‌بینی‌نشده منجر شود.

با واکاوی دقیق‌تر انحرافات (به‌ویژه اختلاف حدوداً ۷ درصدی در معیار RMSE روی مجموعه داده ML-1M)، باید اذعان کرد که ریشه این اختلاف را نمی‌توان صرفاً به تغییر استراتژی بهینه‌سازی تقلیل داد. در یک تحلیل علمی و آسیب‌شناسانه، ابتدا باید نقص‌ها و محدودیت‌های پیاده‌سازی را پذیرفت؛ دلیل اصلی این انحراف به ساده‌سازی‌های صورت‌گرفته در مدل‌سازی ماتریس ویژگی‌های پنهان (V) و ویژگی‌های کمکی (V_A) بازمی‌گردد. در کد توسعه داده شده، نحوه نگاشت و محاسبه تصویر V بر روی V_A با تقریب‌های برنامه‌نویسی همراه بوده که نتوانسته است تمام ظرفیت و ظرافت‌های هندسی تئوری مقاله را منعکس کند.

پس از در نظر گرفتن این نقص ساختاری در کد، تأثیر الگوریتم بهینه‌ساز نیز به‌عنوان عامل تشدیدکننده وارد عمل می‌شود. الگوریتم iRprop+ با در نظر گرفتن تنها علامت گرادیان و تنظیم مستقل اندازه گام برای هر یک از وزن‌ها، عملکرد بسیار مقاومی در مواجهه با ماتریس‌های به شدت خلوت دارد و از محوشدگی گرادیان‌ها بهتر جلوگیری می‌کند. در مقابل، الگوریتم Adam با وجود سرعت هم‌گرایی بالا، در مواجهه با چنین فضای خلوت افراطی‌ای و ترکیب آن با مدل‌سازی ساده شده V و V_A ، مسیر نزول متفاوتی را طی کرده و شبکه را در کمینه‌های محلی متفاوتی متوقف می‌کند. بنابراین، ترکیب محدودیت پیاده‌سازی ویژگی‌ها و تفاوت الگوریتم‌های بهینه‌ساز توجیه‌کننده اصلی این انحرافات در جداول مقایسه‌ای است.

یکی از چالش‌های اساسی در بازتولید دقیق این پژوهش، مواجهه با مسئله نشت داده در متدولوژی مقاله اصلی است. از منظر اصول یادگیری ماشین، تنظیم ابرپارامترها نظیر ضرایب α و β باید بر روی یک مجموعه اعتبارسنجی^{۹۴} مجزا صورت گیرد تا از نشت اطلاعات مجموعه آزمون به فرایند آموزش جلوگیری شود. با این حال، با بررسی دقیق بخش تنظیمات پارامترها در مقاله مرجع، مشخص است که نویسندگان از هیچ مجموعه اعتبارسنجی مستقلی استفاده نکرده و مقادیر بهینه را صرفاً از طریق آزمایش‌های مکرر^{۹۵} بر روی همان پیکربندی آموزش/آزمون استخراج کرده‌اند. این رویکرد باعث می‌شود نتایج گزارش شده در مقاله اصلی، کمی خوش‌بینانه‌تر^{۹۶} از توان واقعی تعمیم‌پذیری مدل باشند.

در پیاده‌سازی این پروژه، از آنجا که هدف نهایی، بازتولید دقیق و وفادارانه به تنظیمات مقاله مرجع بوده است، استراتژی جستجوی شبکه‌ای^{۹۷} دقیقاً مطابق با متدولوژی نویسندگان و بدون جداسازی مجموعه اعتبارسنجی انجام پذیرفت. بدیهی است که در صورت افزودن مجموعه اعتبارسنجی، نتایج به دست آمده به واقعیت نزدیک‌تر می‌شدند، اما مقایسه مستقیم و نظیربه‌نظیر جداول با مقاله اصلی (که خود دچار این سوگیری بوده است) امکان‌پذیر نمی‌بود.

⁹⁴ Validation Set

⁹⁵ Repeated Experiments

⁹⁶ Over-optimistic

⁹⁷ Grid Search

یکی دیگر از تفاوت‌ها و محدودیت‌های این پیاده‌سازی نسبت به مقاله مرجع، تعداد دفعات اجرای آزمایش‌ها است. در متدولوژی مقاله اصلی، برای اطمینان از پایداری نتایج و خنثی‌سازی تأثیر تصادفی بودن در مقداردهی اولیه وزن‌های شبکه عصبی، هر آزمایش ۵ بار تکرار شده و میانگین آن‌ها گزارش شده است. اما در اجرای این پروژه، آزمایش‌ها صرفاً در یک اجرای واحد و با قفل کردن تولیدکننده اعداد تصادفی (seed=42) انجام پذیرفت. اگرچه این رویکرد، تکرارپذیری کد را تضمین می‌کند و برای اثبات فرضیه‌های اصلی معماری در این مقیاس کفایت می‌کند، اما باید اذعان کرد که عدم محاسبه‌ی واریانس و انحراف معیار نتایج، یکی از محدودیت‌هاست.

۵.۳. جمع‌بندی تحلیل‌ها و ارزیابی‌های تجربی

آزمایش‌های گسترده‌ای که بر روی دو مجموعه داده استاندارد (MovieLens-1M و MovieLens-100K) انجام پذیرفت، تمامی ادعاهای تئوری مقاله را به صورت کمی و مستدل تأیید کرد. نتایج نشان داد که معماری پیشنهادی FSTDMF، به ویژه در سناریوهای به شدت خلوت (مانند نسبت آموزش ۳۰ درصد)، توانایی بالایی در کاهش خطای MAE و RMSE نسبت به مدل پایه DMF دارد.

تحلیل‌های حساسیت اثبات کردند که در مجموعه داده‌های با پراکندگی بالا، استفاده از شبکه‌های کم عمق (تک لایه) با ابعاد ویژگی پنهان کنترل شده ($r = 100$)، بهترین استراتژی برای کشف الگوها و همزمان جلوگیری از پدیده بیش‌برازش است. از سوی دیگر، مطالعه فرسایشی (حذف اجزا) به روشنی پرده از راز موفقیت این معماری برداشت: مقداردهی اولیه با نیمه خودمرزگذار نقطه شروع بهینه‌ای را برای نزول گرادیان فراهم می‌کند تا شبکه در کمینه‌های محلی ضعیف گیر نیفتد، درحالی که انتقال زیرفضای ویژگی در طول فرایند آموزش، این مسیر را با اطلاعات جانبی هدایت می‌نماید. ترکیب این دو، یک هم‌افزایی قدرتمند است که پایداری و دقت سیستم توصیه‌گر را به سطح جدیدی ارتقا می‌دهد.

۵.۴. پیشنهاداتی برای پژوهش‌ها و توسعه‌های آتی

اگرچه این چارچوب به اهداف تعیین شده خود در بهبود دقت فاکتورگیری ماتریس عمیق دست یافت، اما مسیر برای توسعه بیشتر این معماری در پایتون همچنان باز است. بر اساس بینش‌های به دست آمده از این پیاده‌سازی، محورهای زیر برای پژوهش‌های آینده پیشنهاد می‌گردد:

- توسعه به سناریوهای متقاطع-دامنه^{۹۸}: در این پیاده‌سازی، تمرکز اصلی بر استفاده از صفات درونی آیتم‌ها (ژانر و سال تولید) قرار داشت. توسعه کدهای فعلی برای دریافت و پردازش ماتریس امتیازات از پلتفرم‌های خارجی می‌تواند ظرفیت انتقال دانش مدل را در شرایطی که هیچ داده صفاتی در دسترس نیست، دوچندان کند.
- ادغام با شبکه‌های عصبی گراف^{۹۹}: با توجه به اینکه تعاملات کاربران و آیتم‌ها ذاتاً یک ساختار گرافی عظیم (گراف دویخشی) را تشکیل می‌دهند، جایگزینی لایه‌های خطی و متراکم فعلی با بلوک‌های شبکه‌های عصبی گراف می‌تواند وابستگی‌های ساختاری و سلسله‌مراتب پیچیده را با دقت بسیار بالاتری استخراج نماید و به کیفیت بازنمایی ویژگی‌های پنهان اضافه کند.

⁹⁸ Cross-domain Scenarios

⁹⁹ Graph Neural Networks (GNNs)

- تعبیه مکانیزم توجه^{۱۰۰}: در معماری فعلی، تمامی صفات استخراج شده از طریق کدگذاری وان-هات، با اهمیتی یکسان به فضای متعامد منتقل می‌شوند. افزودن یک لایه توجه به معماری شبکه اجازه می‌دهد تا مدل به صورت پویا یاد بگیرد که برای هر آیت، به کدام صفت وزن بیشتری اختصاص دهد.
 - اصلاح توابع فعال‌ساز برای غلبه بر محوشدگی گرادیان: با توجه به آسیب‌شناسی انجام شده در تحلیل لایه‌های پنهان، استفاده‌ی پی‌درپی از تابع فعال‌ساز سیگموئید در لایه‌های میانی باعث محوشدگی گرادیان و افت سیستماتیک عملکرد در شبکه‌های عمیق‌تر می‌شود. به عنوان پیشنهاد می‌توان در پیاده‌سازی‌ها و توسعه‌های آتی این معماری، در لایه‌های میانی از توابع فعال‌ساز نوین‌تری مانند ReLU یا LeakyReLU استفاده شود و تابع سیگموئید منحصراً در لایه خروجی (صرفاً برای نگاشت خروجی به بازه نرمال امتیازات) به کار رود. این تغییر ساختاری ساده می‌تواند مشکل محوشدگی را برطرف کرده و امکان بهره‌برداری از قدرت شبکه‌های عمیق‌تر (با دو یا چند لایه پنهان) را فراهم سازد.
- ضمناً کدهای توسعه داده شده به صورت متن‌باز در مخزن گیت‌هاب در دسترس قرار گرفته است:

 github.com/mohsenelahifard/FSTD MF-recommend-system

¹⁰⁰ Attention Mechanism